SEGMENTASI *BURNED AREA* MENGGUNAKAN MODEL U-NET PADA CITRA SENTINEL-2 SUMATERA SELATAN

TUGAS AKHIR

M FARHAN ATHAULLOH
121450117

PROGRAM STUDI SAINS DATA
FAKULTAS SAINS
INSTITUT TEKNOLOGI SUMATERA
2026

SEGMENTASI *BURNED AREA* MENGGUNAKAN MODEL U-NET PADA CITRA SENTINEL-2 SUMATERA SELATAN

TUGAS AKHIR

Diajukan sebagai syarat untuk memperoleh gelar Sarjana

M FARHAN ATHAULLOH
121450117

PROGRAM STUDI SAINS DATA
FAKULTAS SAINS
INSTITUT TEKNOLOGI SUMATERA
2026

HALAMAN PENGESAHAN

Tugas Akhir Sarjana dengan judul "**SEGMENTASI *BURNED AREA* MENGGUNAKAN MODEL U-NET PADA CITRA SENTINEL-2 SUMATERA SELATAN**" adalah benar dibuat oleh saya sendiri dan belum pernah dibuat dan diserahkan sebelumnya, baik sebagian ataupun seluruhnya, baik oleh saya ataupun orang lain, baik di Institut Teknologi Sumatera maupun di institusi pendidikan lainnya.

Lampung Selatan, 19 Januari 2026

Penulis,

M FARHAN ATHAULLOH
NIM. 121450117

Diperiksa dan disetujui oleh,

Pembimbing I	Pembimbing II
Febri Dwi Irawati, M.Si.	**Yuliana, M.Cs.**
NIP. 194508171980031002	**NIP. 199507122024062001**

Disahkan oleh,
Koordinator Program Studi Sains Data
Fakultas Sains
Institut Teknologi Sumatera

Tirta Setiawan, S.Pd., M.Si.
NIP. 199008222022031003

HALAMAN PERNYATAAN ORISINALITAS

Skripsi ini adalah karya saya sendiri dan semua sumber baik yang dikutip maupun yang dirujuk telah saya nyatakan benar.

Nama	:	**M FARHAN ATHAULLOH**
NIM	:	**121450117**
Tanda tangan	:	
Tanggal	:	**19 Januari 2026**

ITERA

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI UNTUK KEPENTINGAN AKADEMIS

Sebagai civitas akademik Institut Teknologi Sumatera, saya yang bertanda tangan di bawah ini:

Nama	:	M FARHAN ATHAULLOH
NIM	:	121450117
Program Studi	:	Sains Data
Fakultas	:	Sains
Jenis karya	:	Tugas Akhir

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan Hak Bebas Royalti Noneksklusif (*Non-Exclusive Royalty Free Right*) kepada Institut Teknologi Sumatera atas karya ilmiah saya yang berjudul:

SEGMENTASI *BURNED AREA* MENGGUNAKAN MODEL U-NET PADA CITRA SENTINEL-2 SUMATERA SELATAN

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Sumatera berhak menyimpan, mengalihmedia/format-kan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di	:	Lampung Selatan
Pada tanggal	:	19 Januari 2026

Yang menyatakan

M FARHAN ATHAULLOH

ABSTRAK

SEGMENTASI *BURNED AREA* MENGGUNAKAN MODEL U-NET PADA CITRA SENTINEL-2 SUMATERA SELATAN

M FARHAN ATHAULLOH (121450117)
Pembimbing I: Febri Dwi Irawati, M.Si.
Pembimbing II: Yuliana, M.Cs.

Pemetaan *burned area* di Provinsi Sumatera Selatan dilakukan dalam penelitian ini dengan memanfaatkan citra multispektral Sentinel-2 Level-2A melalui pendekatan Deep Learning model U-Net. Alur penelitian diawali dengan *preprocessing* data, meliputi *cloud masking* berbasis *Scene Classification Layer* (SCL), penyusunan citra komposit, serta normalisasi reflektansi. Selain itu, indeks spektral seperti NDVI, NBR, dan dNBR dihitung guna menganalisis perubahan vegetasi pascakebakaran. Data masukan diproses melalui tahapan *band stacking* dan dibagi menjadi sejumlah *patch* sebagai data latih. Arsitektur U-Net yang diterapkan menggunakan struktur simetris *encoder–decoder* dengan *skip connection* untuk menjaga detail spasial citra. Input yang digunakan dan output yang dihasilkan arsitektur ini berukuran 512 x 512. Pelatihan model dilakukan menggunakan *optimizer* Adam dengan fungsi aktivasi ReLU dan sigmoid. Berdasarkan hasil evaluasi, model mencatatkan Akurasi 0.88386, *Intersection over Union* (IoU) 0.40269, *Dice Coefficient* 0.57417, dan *Binary Cross-Entropy* 0.20875. Hasil ini mengindikasikan bahwa kombinasi Sentinel-2 dan U-Net cukup efektif dalam segmentasi area terbakar.

Kata kunci: *Burned Area*, *Preprocessing*, Sentinel-2, Segmentasi Citra, U-Net

ABSTRACT

SEGMENTATION BURNED AREA USING U-NET MODEL ON SENTINEL-2 IMAGERY OF SOUTH SUMATRA

M FARHAN ATHAULLOH (121450117)
Advisor I: Febri Dwi Irawati, M.Si.
Advisor II: Yuliana, M.Cs.

Burned area mapping in South Sumatra Province was conducted in this study using Sentinel-2 Level-2A multispectral imagery using a U-Net Deep Learning approach. The research process began with data preprocessing, including Scene Classification Layer (SCL)-based cloud masking, composite image preparation, and reflectance normalization. Furthermore, spectral indices such as NDVI, NBR, and dNBR were calculated to analyze post-fire vegetation changes. The input data was processed through a band stacking process and divided into a number of patches as training data. The U-Net architecture used a symmetric encoder–decoder structure with a skip connection to maintain the spatial details of the image. The input and output dimensions of this architecture were 512 x 512. Model training was performed using the Adam optimizer with ReLU and sigmoid activation functions. Based on the evaluation results, the model recorded an Accuracy of 0.88386, Intersection over Union (IoU) of 0.40389, Dice Coefficient of 0.57417, and Binary Cross-Entropy of 0.20875. These results indicate that the combination of Sentinel-2 and U-Net is quite effective in segmenting burned areas.

Keywords : *Burned Area, Preprocessing, Sentinel-2, Image Segmentation, U-Net.*

MOTTO

Percaya pada proses dan percaya kepada Allah SWT.

HALAMAN PERSEMBAHAN

Terima kasih sudah bertahan sejauh ini. Terima kasih sudah menolak untuk menyerah meski dihadapkan pada ratusan baris kode yang error, revisi yang datang silih berganti, dan malam-malam panjang yang melelahkan. Terima kasih sudah percaya bahwa hari ini hari di mana skripsi ini selesai akan benar-benar datang.

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT atas berkah dan rahmat-Nya sehingga skripsi ini dapat terselesaikan dengan baik. Skripsi ini dibuat untuk menyelesaikan pendidikan jenjang sarjana pada Institut Teknologi Sumatera. Penyusunan skripsi ini banyak mendapat bantuan dan dukungan dari berbagai pihak sehingga dalam kesempatan ini, dengan penuh kerendahan hati, penulis mengucapkan terima kasih kepada:

1. Kedua orang tua dan adik serta keluarga, atas doa yang tak pernah henti dan kasih sayang tanpa batas sepanjang perjalanan ini.
2. Ibu Febri Dwi Irawati, M.Si. selaku dosen pembimbing 1, atas bimbingan, waktu, kesabaran, dan ilmu yang telah diberikan dengan tulus selama proses penyusunan Tugas Akhir ini.
3. Ibu Yuliana, M.Cs. selaku dosen pembimbing 2, atas waktu, arahan, dan masukan berharga yang sangat membantu dalam menyempurnakan tugas akhir ini.
4. Ibu Mika Alvionita S, M.Si. selaku dosen penguji, atas saran, kritik, dan evaluasi yang membangun demi penyempurnaan tugas akhir ini.
5. Teman-teman Sains Data Angkatan 2021 ITERA, atas kebersamaan, semangat, dukungan, dan tawa yang telah menjadi bagian tak terlupakan selama masa perkuliahan. Kalian adalah bagian penting dari perjalanan ini.
6. Nuju, terimakasih sudah menyediakan tempat, wifi, serta minuman favorit penulis yaitu americano dan OTR sampai penulis bisa menyelesaikan proses penyusunan skripsi ini.

Penulis menyadari bahwa penyusunan Skripsi ini jauh dari sempurna. Akhir kata penulis mohon maaf yang sebesar-besarnya apabila ada kekeliruan di dalam penulisan skripsi ini.

Lampung Selatan, 19 Januari 2026

M Farhan Athaulloh

DAFTAR ISI

HALAMAN JUDUL . . . . . **i**

HALAMAN PENGESAHAN . . . . . **ii**

HALAMAN PERNYATAAN ORISINALITAS . . . . . **iii**

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI . **iv**

ABSTRAK . . . . . **v**

ABSTRACT . . . . . **vi**

MOTTO . . . . . **vii**

HALAMAN PERSEMBAHAN . . . . . **viii**

KATA PENGANTAR . . . . . **ix**

DAFTAR ISI . . . . . **xi**

DAFTAR GAMBAR . . . . . **xiii**

DAFTAR TABEL . . . . . **xv**

I PENDAHULUAN **1**

1.1 Latar Belakang 1

1.2 Rumusan Masalah 3

1.3 Tujuan Penelitian 3

1.4 Batasan Masalah 3

II TINJAUAN PUSTAKA **5**

2.1 *Burned Area* 5

2.2 Sentinel-2 6

2.3 Ekstraksi Fitur 7

2.3.1 *Normalized Difference Vegetation Index* (NDVI) . 7

2.3.2 *Normalized Burn Ratio* (NBR) 8

2.3.3 *Diferrence Normalized Burn Ratio* (dNBR) . . . 8

2.3.3.1 *Near-Infrared* (NIR) 9

2.3.3.2 *Short-Wave infrared* (SWIR) 9

2.4 Model *U-Net* 9

2.5 *Hyperparameter* 15

2.5.1 *Batch Size* 16
2.5.2 Adam 16
2.6 Fungsi Aktivasi 16
2.6.1 *Rectified Linear Unit* (ReLU) 16
2.6.2 Sigmoid 17
2.7 *Convolutional*, *Max Pooling* dan *Convolutional Transpose* 17
2.7.1 Lapisan Konvolusi (*Convolutional Layer*) 17
2.7.2 Lapisan *Max Pooling* (*Pooling Layer*) 17
2.7.3 Lapisan *Convolutional Transpose* 18
2.8 Overlapping pada Citra 18
2.9 Evaluasi Model 18
2.9.1 *Binary Accuracy* 18
2.9.2 *Intersection Over Union* 19
2.9.3 *Dice Coefficient* 20
2.9.4 *Binary Cross Entropy* 20

III METODE PENELITIAN 22
3.1 Lokasi Penelitian 22
3.2 Deskripsi Data 22
3.3 Perangkat Komputasi 23
3.4 Tahapan Penelitian 25
3.4.1 *Praprocessing Data* 26
3.4.1.1 *Cloud Masking* 26
3.4.1.2 Citra Komposit 27
3.4.2 Ekstraksi Fitur 27
3.4.2.1 *Normalized Difference Vegetation Index (NDVI)* 27
3.4.2.2 *Normalized Burn Ratio (NBR)* 28
3.4.2.3 *Diferrence Normalized Burn Ratio (dNBR)* . 28
3.4.3 *Band Stacking* 29
3.4.4 *Masking* Citra 29
3.4.5 Split Data 30
3.4.6 Model U-Net 30
3.4.7 Model Evaluasi 32

IV HASIL DAN PEMBAHASAN 33
4.1 Deskripsi Data 33

4.2 *Praprocessing Data* 37
4.2.1 *Cloud Masking* 38
4.2.2 Komposit Citra 40
4.3 Ekstraksi Fitur 41
4.3.1 *Normalized Difference Vegetation Index* (NDVI) . 41
4.3.2 *Normalized Burn Ratio* (NBR) 44
4.3.3 *Difference Normalized Burn Ratio* (dNBR) 47
4.4 *Masking* Citra 50
4.5 *Band Stacking* 52
4.6 *Split Data* 53
4.7 Model U-Net 55
4.8 Evaluasi Model 59
4.9 Pembahasan 62

V KESIMPULAN DAN SARAN 66
5.1 Kesimpulan 66
5.2 Saran 67

DAFTAR PUSTAKA 69

LAMPIRAN 73

DAFTAR GAMBAR

Gambar 2.1 Arsitektur Model *U-Net* [7] 11
Gambar 2.2 *Confussion Matrix* 19

Gambar 3.1 Peta Sumatera Selatan 22
Gambar 3.2 Katalog dataset Sentinel-2 23
Gambar 3.3 Diagram Alir Tahapan Penelitian 26
Gambar 3.4 Ilustrasi (a).Sebelum *Cloud Masking* dan (b).Sesudah *Cloud Masking* 27
Gambar 3.5 Ilustrasi NDVI 28
Gambar 3.6 Ilustrasi NBR 28
Gambar 3.7 Ilustrasi dNBR 29
Gambar 3.8 Arsitektur Model U-Net 31
Gambar 3.9 Ilustrasi Model U-Net 32

Gambar 4.1 Distribusi Reflektansi Pada Tiap Tile, (a).Tile 48MWB *Prefire* (b).Tile 48MWB *Postfire* (c).Tile 48MUC *Prefire* (d).Tile 48MUC *Postfire* (e).Tile 48MVC *Prefire* (f).Tile 48MVC *Postfire*. 35
Gambar 4.2 *Cloud Masking* (SCL) Pada Kondisi *Prefire* dan *Postfire* 40
Gambar 4.3 Histogram NDVI Pada Tiap Tile, (a).Tile 48MWB *Prefire* (b).Tile 48MWB *Postfire* (c).Tile 48MUC *Prefire* (d).Tile 48MUC *Postfire* (e).Tile 48MVC *Prefire* (f).Tile 48MVC *Postfire*. 44
Gambar 4.4 Histogram NBR Pada Tiap Tile, (a).Tile 48MWB *Prefire* (b).Tile 48MWB *Postfire* (c).Tile 48MUC *Prefire* (d).Tile 48MUC *Postfire* (e).Tile 48MVC *Prefire* (f).Tile 48MVC *Postfire*. 47
Gambar 4.5 Histogram dNBR Untuk (a).Tile 48MWB (b).Tile 48MUC dan (c).Tile 48MVC 49

Gambar 4.6 Disribusi Piksel Citra *mask* Tile 48MWB . . . 50
Gambar 4.7 Disribusi Piksel Citra *mask* Tile 48MUC . . . 51
Gambar 4.8 Disribusi Piksel Citra *mask* Tile 48MVC . . . 51
Gambar 4.9 Distribusi Piksel 54
Gambar 4.10 Grafik *Loss* dan *Accuracy* Model 56
Gambar 4.11 Citra Prediksi Segmentasi model U-Net 62

DAFTAR TABEL

Tabel 2.1 Penelitian terkait segmentasi *burned area* . . . 5
Tabel 2.2 Spesifikasi band Sentinel-2 7
Tabel 2.3 Penelitian terdahulu menggunakan model U-Net untuk segmentasi citra. 12
Tabel 2.4 Penelitian terdahulu lainnya dengan model U-Net pada citra satelit. 13
Tabel 2.5 Penelitian lanjutan dengan variasi arsitektur U-Net. 14

Tabel 3.1 Spesifikasi Perangkat Keras Laptop dan Google Colaboratory Pro 24
Tabel 3.2 Spesifikasi Library 25

Tabel 4.1 Daftar Citra Sentinel-2 Kondisi *Prefire* 34
Tabel 4.2 Kelas *Scene Classification Layer* (SCL) Sentinel-2 39
Tabel 4.3 Struktur Layer dan Output Shape Model U-Net 58
Tabel 4.4 Hasil Evaluasi Model 60
Tabel 4.5 *Confussion Matrix* Hasil Prediksi Model . . . 61
Tabel 4.6 Perbandingan performa segmentasi model U-Net 65

BAB I

PENDAHULUAN

1.1 Latar Belakang

Indonesia merupakan negara tropis yang memiliki hutan yang sangat luas dan kaya keanekaragaman hayati. Besarnya cakupan hutan di Indonesia justru menjadikan negara ini sangat rentan terhadap kebakaran hutan dan lahan yang menjadi permasalahan serius dari sisi lingkungan dan kesehatan. Berdasarkan data Kementerian Lingkungan Hidup dan Kehutanan (KLHK) tingkat kebakaran hutan di Indonesia tergolong tinggi, khususnya di wilayah Sumatera [1]. Salah satu provinsi yang sering terdampak ialah Sumatera Selatan, dengan beberapa titik kebakaran tercatat antara tahun 2015 hingga 2023. Meskipun api telah di padamkan di beberapa lokasi petugas masih bersiaga untuk mengantisipasi kemunculan titik api lainnya [1]. Upaya penanggulangan kebakaran dilakukan dengan mengambil data kebakaran tanpa harus turun secara langsung kelapangan dikarenakan pengambilan data secara langsung sangat sulit.

Pengumpulan data mengenai *burned area* sangat penting dalam kegiatan mitigasi, pemulihan ekosistem, serta perencanaan tata guna lahan pascakebakaran. Pendekatan konvensional seperti survei lapangan untuk mengidentifikasi *burned area* memerlukan biaya tinggi, waktu lama, dan akses yang sulit, terutama pada wilayah yang luas dan sulit dijangkau. Oleh karena itu, penggunaan teknologi penginderaan jauh khususnya citra satelit, menjadi alternatif yang efisien dan efektif untuk memantau kondisi hutan dan memetakan area terdampak kebakaran [2]. Salah satu citra satelit yang banyak digunakan dalam pemantauan vegetasi dan area kebakaran adalah Sentinel-2. Citra ini menyediakan data multispektral dengan resolusi spasial tinggi dengan rentang 10 m, 20 m, hingga 60 m dan rentang spektral yang luas, termasuk kanal penting seperti *Near-Infrared* (NIR) dan *Short-Wave Infrared* (SWIR), yang sangat sensitif terhadap perubahan vegetasi akibat kebakaran[3].

Berbagai pendekatan telah dikembangkan untuk mendeteksi area terbakar, mulai dari interpretasi visual hingga klasifikasi digital. Interpretasi visual meskipun akurat, memiliki keterbatasan dalam hal efisiensi waktu dan sumber daya [4]. Oleh karena itu, pendekatan klasifikasi digital berbasis pembelajaran mesin (*machine learning*) dan pembelajaran mendalam (*Deep Learning*) semakin diminati karena efisiensi dan skalabilitasnya dalam menganalisis data citra multiband [5]. Salah satu arsitektur turunan dari *Convolutional Neural Networks* yang digunakan dalam deteksi area spesifik pada citra ialah Arsitektur U-Net. Arsitektur ini memungkinkan segmentasi yang presisi bahkan dengan jumlah data pelatihan yang sangat terbatas, berkat strategi augmentasi data. Dalam tantangan Institut Seni Budaya Indonesia (ISBI) 2015, U-Net berhasil mencapai *Intersection over Union* (IoU) sebesar 92,03% untuk data *PhC-U373* dan 77,56% untuk data *DIC-HeLa*, [6]. Pemilihan model U-Net dalam penelitian ini bukan hanya karena arsitekturnya yang efisien dan akurat, tetapi juga karena U-Net telah menjadi salah satu model *state-of-the-art* (SOTA) dalam berbagai tugas segmentasi citra, baik di bidang medis, pertanian, hingga penginderaan jauh. Beberapa studi telah berhasil mengadaptasi struktur model U-Net untuk segmentasi citra satelit [7][8], Kemampuannya dalam menjaga detail spasial dan menghasilkan segmentasi pada level piksel membuat U-Net sangat cocok diterapkan dalam deteksi area kebakaran lahan berbasis citra satelit multiband.

Penelitian sebelumnya telah menunjukkan bahwa U-Net unggul dalam mengenali pola visual kompleks yang muncul akibat perubahan vegetasi pasca kebakaran. Pada studi literatur [2] menunjukkan bahwa penggunaan citra *false color composite* dengan model berbasis U-Net mampu mengidentifikasi area terbakar dengan akurasi hingga 0.93 dan Loss sekitar 0.07. Adaptasi U-Net untuk klasifikasi diharapkan dapat mempertahankan keunggulan dalam pemrosesan spasial dan menghasilkan prediksi kelas yang efisien untuk setiap unit area. Dalam penelitian ini, dikembangkan model segementasi *burned area* berbasis arsitektur U-Net yang dimodifikasi, dengan memanfaatkan kombinasi band spektral optimal dari Sentinel-2 serta fitur turunan seperti NDVI,

NBR, dan dNBR. Model akan dievaluasi menggunakan metrik akurasi, *dice coefficient*, *IoU* dan *BCE*, guna memastikan bahwa performanya setara atau lebih baik dibandingkan pendekatan klasifikasi lainnya yang telah digunakan sebelumnya.

1.2 Rumusan Masalah

Dalam upaya mewujudkan segmentasi pada *burned area* melalui pemanfaatan data citra Sentinel-2 dengan pendekatan model U-Net, rumusan masalah utama yang diangkat dalam penelitian ini adalah sebagai berikut:

1. Bagaimana teknik praproses dan ekstraksi fitur pada data citra Sentinel-2 dalam mendukung segmentasi *burned area* di daerah Sumatera Selatan?
2. Bagaimana implementasi model U-Net dalam mengidentifikasi *burned area* berdasarkan data citra yang telah proses dan hasil evaluasi dari model?

1.3 Tujuan Penelitian

Adapun tujuan penelitian ini, sebagai berikut:

1. Melakukan praproses dan ekstraksi fitur pada data citra Sentinel-2 untuk meningkatkan kualitas data dalam segmentasi *burned area*.
2. Menerapkan model U-Net dan evaluasi dalam mendeteksi *burned area* dari data citra satelit sentinel-2 yang telah diproses.

1.4 Batasan Masalah

Ruang lingkup penelitian ini dibatasi secara spesifik untuk menjamin fokus analisis dan kesesuaiannya dengan tujuan yang telah ditetapkan. Batasan tersebut mencakup aspek spasial, di mana wilayah kajian (*Area of Interest/AOI*) secara eksklusif adalah wilayah Provinsi Sumatera Selatan. Dari aspek data, sumber data primer yang digunakan adalah data penginderaan jauh dari citra Sentinel-2 Level-2A (L2A) atau *Bottom Of Atmosphere* (BOA), yang telah terkoreksi secara atmosferik. Adapun dari keseluruhan data

Sentinel-2A yang tersedia, penelitian ini hanya akan memproses dan menganalisis data pada tile spesifik 48WMB, 48MUC, dan 48MVC.

BAB II

TINJAUAN PUSTAKA

2.1 *Burned Area*

Kawasan yang terbakar (*burned area*) merupakan hasil dari peristiwa kebakaran yang terjadi di berbagai ekosistem dan area antropogenik, dengan dampak yang luas dari skala lokal hingga global [9]. Secara lokal dan regional, kebakaran memengaruhi perubahan penggunaaan lahan, produktivitas ekosistem, serta keanekaragaman hayati, sedangkan pada skala yang lebih luas, kebakaran dapat memodifikasi siklus hidrologi, biokimia, dan atmosfer [10]. Kebakaran juga menghasilkan emisi gas rumah kaca, terutama karbonat, yang mendominasi dari total emisi akibat pembakaran hutan. Berikut merupakan penelitian terdahulu terkait klasifikasi *burned area* pada tabel 2.1.

Tabel 2.1 Penelitian terkait segmentasi *burned area*

Referensi	**Data**	**Metode**	**Hasil**	**Kelebihan**
P. de la Rosa et al. [11]	Sentinel-1 SAR + Sentinel-2 optik (10 area uji)	CNN gabungan radar-optik	Dice score: SAR (0,57), optik (0,70), gabungan sebanding/lebih baik	Tahan awan, akurasi tinggi di hutan, cocok untuk data multi-sumber.
M. Grippa et al. [7]	Citra mono-temporal Sentinel-2	CNN mono-temporal tanpa *preprocessing*	Segmentasi cepat dan akurat (tanpa pelaporan metrik eksplisit)	Proses otomatis penuh, efisien, cocok untuk deployment cepat.
Prabowo Y. et al. [2]	Citra Landsat-8: False Color (komposit SWIR-2, NIR, Red)	CNN model U-Net dengan 200 *epoch* pelatihan	Jaccard Index: 0,93, Loss: 0,07. *False Color* efektif untuk visualisasi area terbakar	Dataset lokal berkualitas tinggi, visualisasi efektif, arsitektur U-Net sederhana.

2.2 Sentinel-2

Sentinel-2 merupakan pasangan satelit kembar yang dikembangkan oleh *European Space Agency* (ESA) sebagai bagian dari program Copernicus untuk pemantauan bumi. Satelit ini menyediakan data multispektral dengan resolusi spasial yang bervariasi, yaitu 10 meter, 20 meter, dan 60 meter, tergantung pada panjang gelombang spektralnya. Sensor utama pada Sentinel-2 yaitu *Multi Spectral Instrument* (MSI) memiliki 13 kanal spektral yang mencakup daerah spektrum tampak (*Visible*), *Near-Infrared* (NIR), dan *Short-Wave Infrared* (SWIR)[12]. Sentinel-2 merupakan upgrade dari pendahulunya yaitu landast dan spot dimana mengalami perubahan yang signifikan pada bagian lebar kanal dan penambahan kanal untuk penyempurnaan dalam observasi bumi.

Citra produk Sentinel-2 pada level Level-2A menyediakan nilai reflektansi permukaan (*Bottom-Of-Atmosphere*, (BOA)) yang telah melalui koreksi atmosferik dan klasifikasi skena secara otomatis, sehingga data tersebut siap untuk aplikasi lanjutan tanpa perlu koreksi tambahan. Dalam studi oleh Hagolle et al.[13], dijelaskan bahwa proses atmosferik dan kalibrasi sensor MSI yang digunakan dalam produk Level-2A memungkinkan pencapaian konsistensi radiometrik yang baik, dengan ketidakpastian reflektansi di sebagian besar kanal berada di bawah 3% [13]. Berikut deskripsi band sensor beserta panjang band pada citra Sentinel-2 pada tabel 2.2.

Tabel 2.2 Spesifikasi band Sentinel-2

No. Band	Panjang Gelombang (nm)	Deskripsi Band	Kegunaan
1	443	Aerosol	Koreksi atmosferik (hamburan aerosol)
2	490	Blue	Perkembangan vegetasi, karotenoid, keadaan tanah, koreksi atmosferik (hamburan aerosol)
3	560	Green	Puncak sinar hijau, sensitif terhadap total klorofil pada vegetasi
4	665	Red	Absorpsi klorofil maksimum
5	705	Vegetation Red Edge	Konsolidasi koreksi atmosferik, dasar fluoresensi, posisi tepi kanal merah
6	740	Vegetation Red Edge	Deteksi batas warna merah; koreksi atmosferik; penerimaan beban aerosol
7	783	Vegetation Red Edge	Indeks area daun, tepi puncak NIR
8	842	Near-Infrared (NIR)	Indeks area daun
9	865	Vegetation Red Edge	Puncak NIR sensitif terhadap total klorofil, biomassa, indeks tepi daun dan protein; referensi penyerapan uap air; tipe aerosol
10	945	Water Vapour	Koreksi atmosferik untuk absorpsi uap air
11	1380	SWIR - Cirrus	Koreksi atmosferik untuk awan tipis (cirrus)
12	1610	Short Wavelength Infrared (SWIR)	Sensitif terhadap lignin, pati dan biomassa hutan; pemisahan salju/es/awan
13	2190	Short Wavelength Infrared (SWIR)	Penilaian kondisi vegetasi; pemantauan erosi tanah; pembedaan biomassa hidup, mati dan tanah

2.3 Ekstraksi Fitur

2.3.1 *Normalized Difference Vegetation Index* (NDVI)

NDVI digunakan untuk mengukur kesehatan vegetasi pada suatu area. Indeks ini membantu membedakan vegetasi yang sehat dari area yang tidak tertutup vegetasi [14].

$$NDVI = \frac{NIR - Red}{NIR + Red} \tag{2.1}$$

Keterangan:

1. NDVI: Indeks Vegetasi Ternormalisasi, digunakan untuk mengukur tingkat kerapatan dan kesehatan vegetasi.
2. NIR (*Near Infrared*): Band inframerah-dekat yang sensitif terhadap kandungan klorofil pada vegetasi.
3. *Red*: Band merah yang menyerap energi dari vegetasi sehat.

2.3.2 *Normalized Burn Ratio* (NBR)

NBR dirancang untuk mendeteksi area yang terbakar. NBR sangat sensitif terhadap perubahan vegetasi dan kandungan karbonisasi tanah akibat kebakaran [15].

$$NBR = \frac{NIR - SWIR2}{NIR + SWIR2} \tag{2.2}$$

Keterangan:

1. NBR: Rasio Kebakaran Ternormalisasi, digunakan untuk mendeteksi area terbakar dan perubahan vegetasi akibat kebakaran.
2. NIR (*Near Infrared*): Band inframerah-dekat yang sensitif terhadap kandungan klorofil pada vegetasi.
3. SWIR2 (*Shortwave Infrared* 2): Band inframerah-pendek, sensitif terhadap perubahan kelembapan tanah dan karbonisasi akibat kebakaran.

2.3.3 *Diferrence Normalized Burn Ratio* (dNBR)

dNBR merupakan kondisi area yang diteliti sesudah dan sebelum area terjadi kebakaran (*prefire* dan *postfire*). Langkah awal untuk menentukan dNBR yaitu melakukan perhitungan NBR lalu dNBR digunakan untuk menghitung selisih antara nilai NBR sebelum dan sesudah kebakaran. Nilai dNBR yang rendah memperlihatkan area yang lebih ringan atau tidak terbakar, sedangkan jika tinggi

memperlihatkan vegetasi mengalami kerusakan akibat kebarakan [16].

$$dNBR = NBRprefire - NBRpostfire \tag{2.3}$$

NBRp*refire* merupakan indeks NBR sebelum kejadian kebakaran dan NBR*posfire* merupakan indeks setelah kejadian kebakaran.

2.3.3.1 *Near-Infrared* (NIR)

Spektroskopi *Near-Infrared* (NIR) merupakan teknik spektroskopi yang memanfaatkan daerah panjang gelombang 780–2500 nm, yang berada di antara spektrum cahaya tampak dan inframerah tengah. Salah satu keunggulan utama NIR dibandingkan teknik spektroskopi lainnya adalah kemampuannya untuk menembus berbagai bahan tanpa perlu persiapan sampel yang rumit, sehingga sering digunakan dalam aplikasi industri, biomedis, dan lingkungan [17]. Spektrum NIR dapat memberikan informasi mengenai komposisi kimia suatu material, termasuk kadar air, protein, dan lemak, yang membuatnya populer dalam industri pangan dan farmasi.

2.3.3.2 *Short-Wave infrared* (SWIR)

Short-Wave Infrared (SWIR) merupakan salah satu spektrum elektromagnetik yang memainkan peran penting dalam mendeteksi dan memetakan area pembakaran. SWIR memiliki rentang panjang gelombang dari 1,1 hingga 2.5, yang membuatnya sangat sensitif terhadap perubahan kelembaban dan kadar air dalam vegetasi dan tanah *infrared* (NIR) [8]. Kemampuan SWIR dalam perbedaan area pembakaran daerah tidak diperlakukan lebih tinggi dari pita spektroskopi lainnya.

2.4 Model *U-Net*

U-Net merupakan arsitektur jaringan saraf konvolusional (CNN) yang dirancang khusus untuk tugas segmentasi citra, pertama kali diperkenalkan oleh Ronneberger pada tahun 2015 dalam bidang

biomedical imaging [6]. U-Net memiliki bentuk khas menyerupai huruf "U", yang terdiri dari dua komponen utama jalur kontraktif (*encoder*) dan jalur ekspansif (*decoder*), serta *skip connection* yang menghubungkan keduanya secara simetris. Bagian *encoder* bertujuan untuk menangkap konteks global dari citra dengan melakukan ekstraksi fitur secara bertahap. Komponen ini terdiri dari beberapa blok konvolusi berlapis-lapis. Bagian tengah dari arsitektur U-Net merupakan *bottleneck*, yang memiliki lapisan konvolusi dengan filter paling banyak. Model memperoleh representasi fitur paling abstrak yang penting untuk segmentasi yang presisi. *Bottleneck* menghubungkan bagian *encoder* dan *decoder*. *Decoder* bertugas untuk merekonstruksi citra dari fitur yang telah dipelajari, dengan mengembalikan dimensi spasial citra menggunakan upsampling atau *transposed convolution* [18].

Salah satu keunggulan utama U-Net adalah adanya *skip connection* yang menghubungkan fitur dari lapisan *encoder* ke lapisan *decoder* yang selevel. Tujuannya adalah untuk mempertahankan informasi spasial resolusi tinggi yang mungkin hilang selama proses *downsampling*. Dengan menggabungkan fitur global (dari *encoder*) dan lokal (dari *decoder*), U-Net mampu menghasilkan segmentasi dengan batas objek yang lebih presisi [18]. Model U-Net yang digunakan memiliki arsitektur *encoder-decoder* simetris. Pada tahap *encoder*, citra *multiband* diproses melalui dua lapisan konvolusi 3×3 yang diikuti dengan operasi *max pooling*, bertujuan untuk mengurangi ukuran spasial dan mengekstraksi fitur. Setelah mencapai *bottleneck*, fitur kemudian dikembalikan ke ukuran spasial semula melalui tahap *decoder* dengan proses *upsampling*. *Skip connection* dari lapisan *encoder* digunakan untuk mempertahankan informasi spasial yang penting. Proses ini diakhiri dengan lapisan konvolusi 1×1 dan proses *sigmoid*. Persamaan dari arsitektur U-Net dapat terlihat pada Rumus 2.4.

$$X_{\text{up}} = W_t \star X + b_t \ , \tag{2.4}$$

Keterangan:

1. X : Input fitur pada *decoder*.
2. X_{up} : Output setelah proses *up-sampling*.
3. W_t : Bobot *transposed convolution*.
4. $\star$: Operasi *convolution transpose*.
5. b_t : Bias.

Arsitektur lengkap dari model U-Net dapat dilihat pada Gambar 2.1, yang memperlihatkan alur proses mulai dari input citra, proses *downsampling*, *bottleneck*, hingga *upsampling*, termasuk *skip connection* yang menjadi ciri khas utama dari U-Net. Lalu studi Literatur model U-Net dapat dilihat pada Tabel 2.3 yang menyajikan ringkasan penelitian terdahulu terkait model U-Net. Tabel ini memuat berbagai pendekatan, data yang digunakan, serta hasil evaluasi dari masing-masing studi.

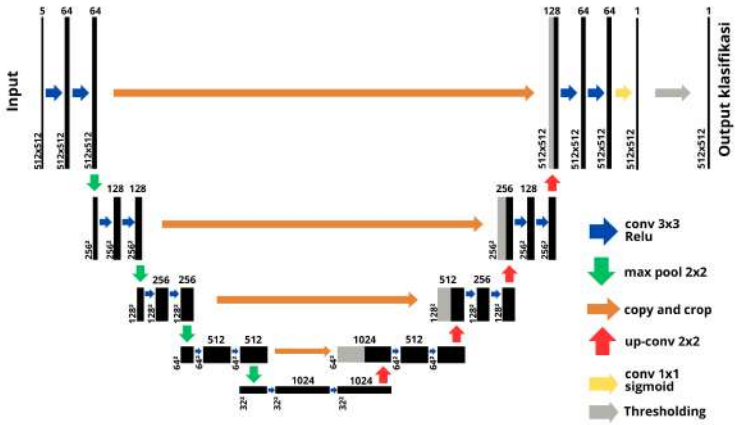

Gambar 2.1 Arsitektur Model *U-Net* [7]

Tabel 2.3 Penelitian terdahulu menggunakan model U-Net untuk segmentasi citra.

Referensi	Data	Hasil	Arsitektur / Contoh Gambar
Olaf Ronneberger, dkk (2015) [6]	Citra Biomedis Mikroskopis (Neuron struktur)	U-Net berhasil meningkatkan segmentasi citra biomedis dengan akurasi tinggi, mencatat IOU 92% (PhC-U373), 77.5% (DIC-HeLa), serta *warping error* 0.00035 pada data neuron EM. Model ini juga sangat cepat, memproses gambar kurang dari 1 detik di GPU.	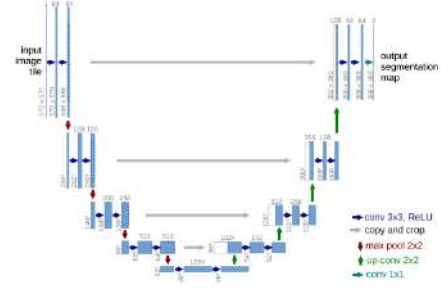
Knopp, L. et al. (2020) [7]	Citra mono-temporal Sentinel-2	U-Net mencapai akurasi keseluruhan 0.98 dan koefisien kappa 0.94 untuk segmentasi area terbakar menggunakan kombinasi band visual, NIR, dan SWIR.	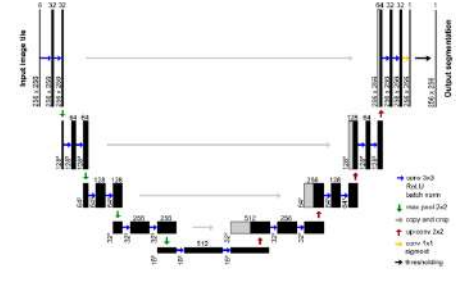

Tabel 2.4 Penelitian terdahulu lainnya dengan model U-Net pada citra satelit.

Referensi	Data	Hasil	Arsitektur / Contoh Gambar
Yudhi Prabowo, dkk (2022) [2]	Landsat-8 TOA	Model U-Net menunjukkan kinerja baik dengan *Jaccard Index* 0.93 dan nilai *loss* 0.07 setelah 200 *epoch* pelatihan. Penggunaan *false color composite* (SWIR-2, NIR, Red) terbukti efektif untuk visualisasi area terbakar.	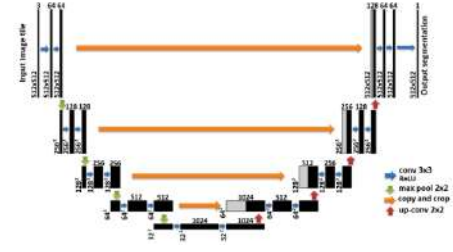 Arsitektur mengambil referensi dari olaf, namun dijelaskan bahwa jumlah filter awal berkisar antara 16–32.
Made Murwantara, dkk (2023) [19]	Landsat-8 dan Sentinel-2	Model terbaik menggunakan citra False Color pada Landsat-8 mencapai akurasi 0.95, IoU 0.78, Dice Coefficient 0.69, dan Binary Cross-Entropy Loss 0.14. Citra False Color lebih efektif dalam mengidentifikasi area terbakar dibandingkan Natural Color.	

Tabel 2.5 Penelitian lanjutan dengan variasi arsitektur U-Net.

Referensi	Data	Hasil	Arsitektur / Contoh Gambar
Won Kyung Baek, dkk (2024) [20]	Sentinel-2	Model SiU-Net dengan input terpisah RGB dan NIR mampu meningkatkan akurasi klasifikasi tutupan lahan dibandingkan U-Net dan DeepLabV3+, dengan F1 Score tertinggi 0.797. SiU-Net efektif mengurangi bias pada data tidak seimbang dan lebih baik dalam mendeteksi batas objek, terutama pada kelas minoritas.	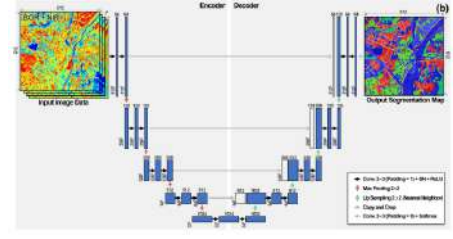

Berikut merupakan pseudocode dasar dari arsitektur U-Net.

Algorithm 1: Pseudocode Arsitektur Model U-Net Modifikasi (Input 5 Channel)

[1] Input Tensor X dengan dimensi $512 \times 512 \times 5$ Binary Segmentation Mask Y
UNet_Model$X$ **— Encoder (Contracting Path) —**
$c1 \leftarrow DoubleConvX, 64$ Output: $512^2 \times 64$ $p1 \leftarrow MaxPoolc1$ Output: $256^2 \times 64$
$c2 \leftarrow DoubleConvp1, 128$ Output: $256^2 \times 128$ $p2 \leftarrow MaxPoolc2$ Output: $128^2 \times 128$
$c3 \leftarrow DoubleConvp2, 256$ Output: $128^2 \times 256$ $p3 \leftarrow MaxPoolc3$ Output: $64^2 \times 256$
$c4 \leftarrow DoubleConvp3, 512$ Output: $64^2 \times 512$ $p4 \leftarrow MaxPoolc4$ Output: $32^2 \times 512$
— Bottleneck — $bn \leftarrow DoubleConvp4, 1024$ Output: $32^2 \times 1024$
— Decoder (Expansive Path) — $u1 \leftarrow UpSamplebn, 512$ Up-conv 2×2 $m1 \leftarrow Concatenateu1, c4$ Skip Connection $d1 \leftarrow DoubleConvm1, 512$
$u2 \leftarrow UpSampled1, 256$ $m2 \leftarrow Concatenateu2, c3$ $d2 \leftarrow DoubleConvm2, 256$
$u3 \leftarrow UpSampled2, 128$ $m3 \leftarrow Concatenateu3, c2$ $d3 \leftarrow DoubleConvm3, 128$
$u4 \leftarrow UpSampled3, 64$ $m4 \leftarrow Concatenateu4, c1$ $d4 \leftarrow DoubleConvm4, 64$
— Output Layer — $out \leftarrow Conv2Dd4, 1, 1 \times 1$, 'sigmoid' $Y \leftarrow Thresholdingout, 0.5$ **return** Y
DoubleConv$input, filters$ $x \leftarrow Conv2Dinput, filters, 3 \times 3$ $x \leftarrow ReLUx$ $x \leftarrow Conv2Dx, filters, 3 \times 3$ $x \leftarrow ReLUx$ **return** x

2.5 *Hyperparameter*

Hyperparameter pada *deep learning* merupakan variabel eksternal yang ditetapkan sebelum proses pelatihan dimulai, seperti *learning rate*, ukuran *batch*, dan fungsi aktivasi. Tidak seperti parameter model yang dipelajari dalam data, *hyperparameter* mengontrol cara model belajar dan sangat mempengaruhi performa model [21].

2.5.1 *Batch Size*

Ukuran *batch* (*batch size*) merupakan salah satu *hyperparameter* krusial dalam pelatihan model *deep learning* yang mendefinisikan jumlah sampel data yang diproses dalam satu iterasi sebelum model melakukan pembaruan bobot (*weight update*) [22]. Disini saya menggunakan *batch size* yaitu 4, penggunaan *batch size* yang besar, meskipun mempercepat waktu komputasi, cenderung mengalami penurunan performa ketika dihadapkan pada data baru berkebalikan dengan ukuran *batch* kecil.

2.5.2 Adam

Proses pelatihan model U-Net pada penelitian ini memanfaatkan Adam (*Adaptive Moment Estimation*) sebagai algoritma optimasinya. Adam merupakan pengembangan dari metode SGD (*Stochastic Gradient Descent*) yang mengkombinasikan keunggulan *AdaGrad* dan *RMSProp* untuk melakukan penyesuaian laju pembelajaran secara adaptif pada setiap parameter [23]. Kemampuan adaptif dari *optimizer* Adam membuatnya sangat andal dalam mengolah data yang kompleks seperti citra satelit Sentinel-2, Citra semacam ini memiliki informasi yang sangat beragam. Adam dengan cerdas mengatur cara model belajar dari berbagai fitur yang ada, sehingga model dapat mencapai kondisi stabil (konvergensi) dengan lebih cepat [23]. Adam digunakan dalam penelitian ini untuk mempercepat proses pelatihan dan memastikan model menemukan solusi terbaik.

2.6 Fungsi Aktivasi

2.6.1 *Rectified Linear Unit* (ReLU)

Dalam konteks segmentasi citra Sentinel-2 untuk mendeteksi area terbakar menggunakan arsitektur U-Net, fungsi aktivasi *Rectified Linear Unit* (ReLU) memegang peranan penting. Fungsi ini bertugas memperkuat fitur spasial dan spektral yang relevan melalui transformasi non-linear [24]. Prinsip kerja ReLU adalah dengan mempertahankan nilai input positif dan mengubah semua nilai input negatif menjadi nol. Pendekatan ini memiliki dua keuntungan utama:

pertama, sangat efisien dari segi komputasi; kedua, terbukti efektif dalam mengatasi masalah gradien yang menghilang (*vanishing gradient*) yang sering menghambat pelatihan [24].

2.6.2 Sigmoid

Fungsi aktivasi Sigmoid merupakan sebuah fungsi non-linear yang lazim diterapkan dalam arsitektur jaringan saraf tiruan, khususnya untuk menangani tugas klasifikasi biner. Untuk merepresentasikan probabilitas sebuah piksel pada citra satelit sebagai area terbakar atau tidak, fungsi aktivasi Sigmoid dapat digunakan dengan memetakan semua nilai input ke rentang antara 0 dan 1 [25].

2.7 *Convolutional*, *Max Pooling* dan *Convolutional Transpose*

2.7.1 Lapisan Konvolusi (*Convolutional Layer*)

Konvolusi (*Convolution*) merupakan operasi utama dalam *Convolutional Neural Network* (CNN) yang berfungsi untuk mengekstraksi fitur spasial dari citra melalui penggunaan filter atau kernel berukuran kecil yang bergerak di atas citra input. Proses ini menghasilkan *feature map* yang merepresentasikan pola penting seperti tepi, tekstur, atau bentuk objek pada citra. Dalam konteks citra satelit Sentinel-2, konvolusi membantu jaringan saraf mengenali struktur spasial area terbakar berdasarkan variasi spektral antar piksel. Keunggulan utama operasi konvolusi terletak pada kemampuannya dalam menangkap informasi lokal dengan jumlah parameter yang lebih sedikit dibandingkan jaringan *fully connected*, sehingga meningkatkan efisiensi komputasi [26].

2.7.2 Lapisan *Max Pooling* (*Pooling Layer*)

Max Pooling merupakan salah satu operasi *downsampling* dalam arsitektur CNN yang berfungsi untuk mengurangi dimensi spasial *feature map* tanpa menghilangkan informasi penting. Operasi ini bekerja dengan memilih nilai maksimum dalam jendela kecil pada *feature map*, sehingga hanya fitur yang paling dominan yang dipertahankan. Pendekatan ini membantu model menjadi lebih tahan

terhadap translasi kecil dan mengurangi kompleksitas komputasi pada tahap pelatihan. Dalam konteks segmentasi area terbakar, *max pooling* membantu mempertahankan fitur utama yang menunjukkan perbedaan jelas antara area terbakar dan tidak terbakar [27].

2.7.3 Lapisan *Convolutional Transpose*

Transpose Konvolusi (Transposed Convolution), juga dikenal sebagai *deconvolution* atau *up-convolution*, merupakan operasi yang digunakan untuk meningkatkan kembali resolusi spasial dari *feature map* hasil proses konvolusi dan *pooling*. Dalam arsitektur seperti U-Net, *transpose* konvolusi berfungsi untuk melakukan *upsampling* agar ukuran keluaran kembali sesuai dengan ukuran citra input, memungkinkan model menghasilkan peta segmentasi piksel demi piksel. Proses ini secara matematis membalikkan arah operasi konvolusi standar dengan memperluas area fitur melalui kernel pembobotan yang dapat dilatih [28].

2.8 Overlapping pada Citra

Overlapping citra merupakan teknik pemotongan (*patching*) citra yang dilakukan dengan memberikan area tumpang tindih antar *patch*, biasanya dalam persentase tertentu seperti 10–50%. Tujuan utama *overlapping* adalah untuk menghindari kehilangan informasi pada tepi *patch* yang sering terjadi saat citra dibagi secara terpisah tanpa tumpang tindih. Dalam konteks *deep learning* untuk segmentasi citra, seperti pada model U-Net, teknik *overlapping* membantu meningkatkan kesinambungan hasil prediksi antar *patch* serta mengurangi artefak pada batas segmentasi. Metode ini sangat berguna pada citra satelit beresolusi tinggi, di mana fitur penting seperti batas area terbakar atau vegetasi dapat berada di tepi *patch* [29].

2.9 Evaluasi Model

2.9.1 *Binary Accuracy*

Binary Accuracy merupakan metrik evaluasi yang digunakan untuk mengukur sejauh mana model klasifikasi biner, seperti segmentasi area

terbakar dan tidak terbakar, mampu memprediksi label dengan benar. Metrik ini menghitung proporsi jumlah piksel yang diklasifikasikan dengan benar terhadap total jumlah piksel. Nilai *binary accuracy* dihitung berdasarkan Persamaan 2.4.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{2.4}$$

di mana TP (*True Positive*) merupakan hasil ketika model secara tepat memprediksi kelas positif, TN (*True Negative*) menunjukkan kasus ketika model secara benar memprediksi kelas negatif, FP (*False Positive*) adalah kondisi ketika model salah memprediksi kelas negatif sebagai positif, dan FN (*False Negative*) terjadi ketika model gagal mendeteksi kelas positif dan justru mengklasifikasikannya sebagai negatif [19]. Gambar 2.2 menggambarkan ilustrasi dari perolehan *confusion matrix* [30].

Actual \ Predicted	Yes	No
Yes	True Positives (TP)	False Negatives (FN)
No	False Positives (FP)	True Negatives (TN)

Gambar 2.2 *Confussion Matrix*

2.9.2 *Intersection Over Union*

Intersection over Union (IoU) merupakan salah satu metrik evaluasi utama dalam tugas segmentasi citra yang digunakan untuk mengukur tingkat kesesuaian antara hasil prediksi model dan area sebenarnya (*ground truth*) [31]. Metrik ini dihitung dengan membandingkan luas area perpotongan (*intersection*) antara prediksi dan label sebenarnya terhadap luas gabungan (*union*) keduanya, berdasarkan Persamaan 2.5.

$$Accuracy = \frac{TP}{TP + FP + FN} \tag{2.5}$$

di mana TP (*True Positive*) menunjukkan jumlah piksel yang diprediksi benar sebagai kelas positif, FP (*False Positive*) adalah piksel yang salah diklasifikasikan sebagai positif, dan FN (*False Negative*)

adalah piksel yang seharusnya positif tetapi tidak terdeteksi oleh model. Nilai IoU berkisar antara 0 hingga 1, dengan nilai mendekati 1 menunjukkan bahwa hasil segmentasi model semakin sesuai dengan data referensi [19].

2.9.3 *Dice Coefficient*

Dice Coefficient, juga dikenal sebagai *Sorensen Dice Index* atau F1 *Score* dalam konteks segmentasi citra biner, merupakan metrik evaluasi yang digunakan untuk mengukur tingkat kesamaan antara hasil prediksi model dan data referensi (*ground truth*). Metrik ini menilai sejauh mana dua area tumpang tindih secara spasial dan sangat umum digunakan dalam tugas segmentasi semantik [32]. Nilai *Dice Coefficient* dapat dihitung berdasarkan Persamaan 2.6.

$$Accuracy = \frac{2xTP}{(2xTP) + FP + FN} \tag{2.6}$$

di mana TP (*True Positive*) merupakan jumlah piksel yang diprediksi dengan benar sebagai kelas positif, FP (*False Positive*) adalah piksel yang salah diklasifikasikan sebagai positif, dan FN (*False Negative*) adalah piksel positif yang tidak terdeteksi oleh model [19]. Nilai *Dice* berkisar antara 0 hingga 1, dengan nilai yang mendekati 1 menunjukkan tingkat kesesuaian yang tinggi antara hasil prediksi dan referensi sebenarnya.

2.9.4 *Binary Cross Entropy*

Binary Cross-Entropy (BCE) merupakan fungsi *loss* yang umum digunakan dalam permasalahan klasifikasi biner, termasuk pada tugas segmentasi citra dua kelas seperti identifikasi area terbakar dan tidak terbakar. Fungsi ini mengukur selisih antara distribusi probabilitas hasil prediksi model dan label sebenarnya (*ground truth*) [19]. Secara matematis, *Binary Cross-Entropy* dihitung berdasarkan Persamaan 2.7.

$$L_{BCE} = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log(p_i) + (1 - y_i)\log(1 - p_i)\right] \tag{2.7}$$

Keterangan:

1. y_i merupakan label sebenarnya (0 untuk kelas negatif dan 1 untuk kelas positif),
2. p_i adalah probabilitas hasil prediksi model untuk piksel ke-i, dan
3. N menunjukkan jumlah total piksel yang digunakan dalam proses pelatihan model.

BAB III

METODE PENELITIAN

3.1 Lokasi Penelitian

Penelitian ini berfokus pada Provinsi Sumatera Selatan, yang terletak di antara 1° – 4° Lintang Selatan dan 102° – 106° Bujur Timur (Gambar 3.1). Dengan luas mencapai 87.017,41 km², wilayah ini memiliki beragam karakteristik geografis seperti dataran rendah, rawa gambut, dan perbukitan. Kondisi ini membuat Sumatera Selatan lebih rentan terhadap kebakaran hutan dan lahana terutama saat musim kemarau. Oleh karena itu, penting untuk menganalisis pola persebaran *burned area* guna memahami kejadian kebakaran di wilayah ini. Peta wilayah Sumatera Selatan dapat terlihat pada Gambar 3.1.

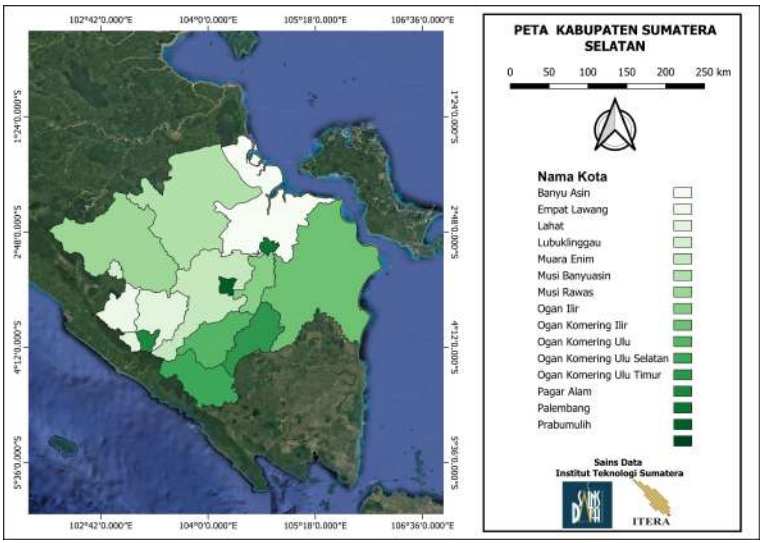

Gambar 3.1 Peta Sumatera Selatan

3.2 Deskripsi Data

Penelitian ini menggunakan data citra satelit Sentinel-2 yang diakses melalui platform Google Earth Engine (GEE) yang diintegrasi dijalankan bersamaan menggunakan Google Colab. Data Sentinel yang digunakan yaitu *Harmonized Sentinel*-2 MSI (*MultiSpectral Instrument*), Level-2A (SR) dengan *ID Collection* di GEE yaitu

COPERNICUS/S2_SR/20151128T002653_20151128T102149_T56MNN. Bagian numerik pertama mewakili tanggal dan waktu persepsi, bagian numerik kedua mewakili tanggal dan waktu pembuatan produk, terakhir string 6 karakter terakhir adalah ID granul unik yang menunjukkan referensi petak UTM-nya.

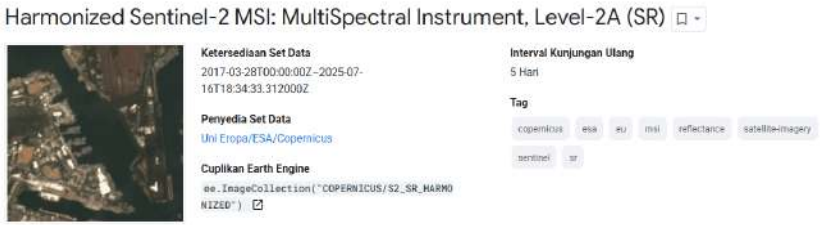

Gambar 3.2 Katalog dataset Sentinel-2

Data penelitian diambil dari wilayah Povinsi Sumatera Selatan pada rentang bulan Januari 2023 - Juli 2024 yang memiliki area lahan dan hutan dalam kondisi sebelum dan sesudah kebakaran. *prefire*(sebelum kebakaran) menggunakan rentang waktu 1 Januari 2023 - 31 Juli 2023 dan *postfire*(sesudah kebakaran) pada rentang waktu 1 November 2023 - 31 Juli 2024, serta kondisi kebakaran terjadi pada bulan Agustus 2023 - Oktober 2023.

3.3 Perangkat Komputasi

Penelitian ini menggunakan perangkat keras komputasi dalam menjalankan program dan penulisan draft yaitu laptop ACER Aspire E5-476G serta penggunaan Google Colaboratory Pro dalam pemrograman daring berbasis notebook, dengan spesifikasi yang ditunjukkan pada Tabel 3.1.

Tabel 3.1 Spesifikasi Perangkat Keras Laptop dan Google Colaboratory Pro

Spesifikasi	**Detail**
Prosesor	Intel Core i3-6006U
Akselerator	L4 GPU
CPU Core	2
Tipe GPU	NVIDIA
GPU Memory	22.5 GB
RAM	53.0 GB
Disk Space	112.6 GB

Selain perangkat keras, penelitian ini juga memanfaatkan beberapa perangkat lunak pendukung, seperti QGIS untuk pengolahan data spasial, Google Earth Engine untuk pengambilan dan praproses data citra Sentinel-2, serta Google Colab Pro sebagai lingkungan komputasi berbasis *cloud* dalam proses pelatihan dan evaluasi model *deep learning*. serta Google Colaboratory Pro digunakan dalam melakukan *training* model U-Net serta evaluasi model. Pada Tabel 3.2 menunjukkan *library* yang digunakan pada proses komputasi.

Tabel 3.2 Spesifikasi Library

Library	Kegunaan
ee	Akses dan praproses data dari *Google Earth Engine*
Pandas	Manipulasi data
Numpy	Manipulasi array atau matriks
Folium	Visualisasi data spasial
Geemap	Membuat peta interaktif
Rasterio	Membaca dan memanipulasi data raster geospasial
Patchify	Memotong gambar besar menjadi patch kecil
Matplotlib	Membuat grafik, plot, dan visualisasi data
Tensorflow	Membangun model *machine learning* dan *deep learning*
GDAL	Membaca dan mengolah data geospasial

3.4 Tahapan Penelitian

Tahapan penelitan yang dilakukan pada penelitan ini, dimulai dari studi literatur hingga evaluasi model. Tahap pengumpulan data, dilakukan dengan mengumpulkan citra satelit Sentinel-2 yang diakses melalui *ID Collection* Sentinel-2 di GEE. Setelah data dikumpulkan dilakukan proses *preprocessing*, terdapat beberapa proses salah satunya yaitu *cloud masking* hingga menghasilkan citra *multiband*. Setelah melalui tahap *preprocessing* data akan dibagi menjadi 3 bagian yaitu *training*, *testing* dan *validation*. Selanjutnya masuk ke proses model U-Net data yang diinput akan melalui beberapa tahapan di model, input dari model ini adalah data *train* dan data *validation*. Tahapan terakhir yaitu evaluasi, pada tahapan evaluasi akan dilakukan perhitungan *Accuracy*, *Intersection Over Union*, *Dice Coefficient* dan *Binary Cross Entropy*. Gambaran dari tahapan penelitian dapat dilihat pada Gambar 3.3.

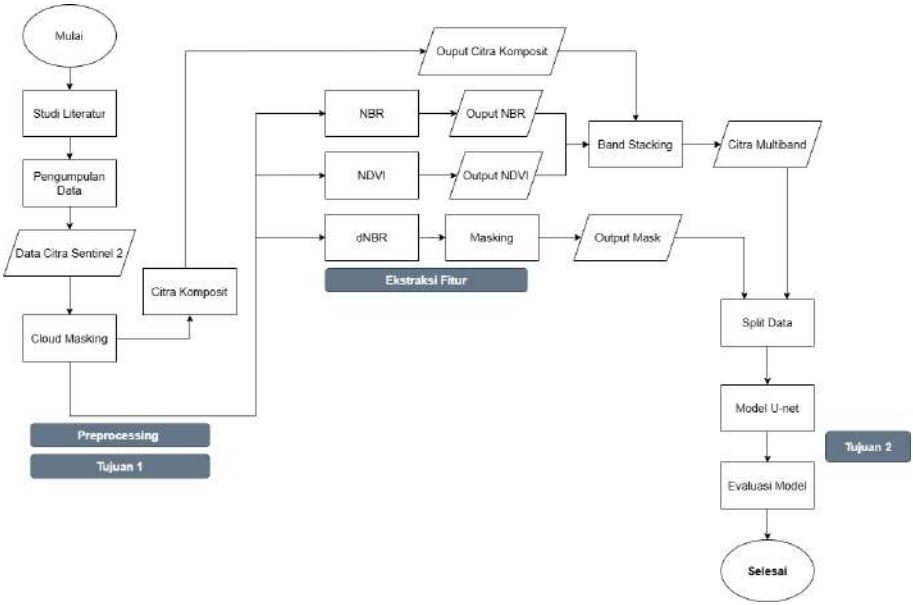

Gambar 3.3 Diagram Alir Tahapan Penelitian

3.4.1 *Praprocessing Data*

Tahapan penelitian diawali dengan data *preprocessing* berdasarkan Gambar 3.3, berfungsi untuk mempersiapkan data yang akan digunakan.

3.4.1.1 *Cloud Masking*

Proses *cloud masking* dilakukan untuk menyaring piksel yang tertutup awan dan bayangan awan agar tidak mengganggu analisis data. Sentinel-2 Level-2A digunakan karena sudah menyertakan *Scene Classification Layer* (SCL) yang menyediakan informasi klasifikasi piksel, seperti awan, bayangan awan, vegetasi, dan air. Piksel dengan kategori probabilitas awan tinggi, awan cirrus, dan bayangan awan yang diidentifikasi akan dihapus dari data menggunakan algoritma masking berbasis SCL. Proses ini bertujuan untuk memastikan bahwa hanya piksel yang bersih dan relevan yang digunakan dalam tahap analisis selanjutnya. Ilustrasi hasil *cloud masking* dapat terlihat pada Gambar 3.4.

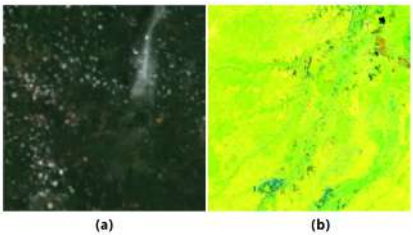

Gambar 3.4 Ilustrasi (a).Sebelum *Cloud Masking* dan (b).Sesudah *Cloud Masking*

3.4.1.2 Citra Komposit

Citra komposit digunakan untuk meningkatkan kejelasan visual dalam mendeteksi area terbakar dengan menggabungkan beberapa band spektral yang sensitif terhadap perubahan vegetasi dan kondisi lahan pasca kebakaran. Pada Sentinel-2, kombinasi *Shortwave Infrared* (SWIR), *Near-Infrared* (NIR), dan *Red* digunakan untuk membuat citra komposit *false color* yang memudahkan analisis, Kombinasi band yaitu band 11 (SWIR), band 8 (NIR) dan band 4 (Red). Kombinasi band ini menghasilkan citra *false color* di mana *burned area* sering tampak gelap atau memiliki warna kontras tertentu terhadap vegetasi dan area yang tidak terbakar.

3.4.2 Ekstraksi Fitur

3.4.2.1 *Normalized Difference Vegetation Index (NDVI)*

Langkah berikutnya ialah menghitung NDVI dari citra Sentinel-2 yang telah melalui tahap pra-pemrosesan. NDVI ini akan dimanfaatkan sebagai salah satu kanal dalam citra *multiband* yang digunakan sebagai input untuk model. Proses penghitungan NDVI dimulai dengan memilih kanal yang sesuai, yaitu band 8 (*Near-Infrared*) dan band 4 (*Red*). Perhitungan NDVI kemudian dilakukan menggunakan persamaan yang tercantum dalam Persamaan 2.1. Hasil dari proses ini berupa citra raster yang menggambarkan distribusi kerapatan vegetasi pada wilayah pengamatan dapat terlihat pada Gambar 3.5.

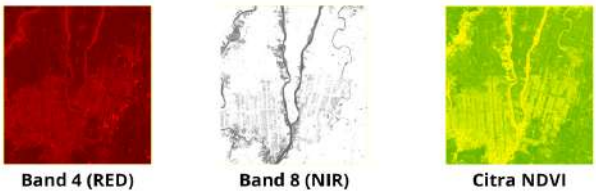

Gambar 3.5 Ilustrasi NDVI

3.4.2.2 *Normalized Burn Ratio (NBR)*

Setelah citra Sentinel-2 melewati tahap pra-pemrosesan, dilakukan perhitungan indeks NBR (*Normalized Burn Ratio*) yang akan digunakan sebagai salah satu kanal dalam citra *multiband* untuk keperluan input model. Proses ini dimulai dengan memilih band yang relevan, yaitu band 8 (*Near-Infrared*/NIR) dan band 12 (*Shortwave Infrared*/SWIR). Penghitungan NBR dilakukan menggunakan rumus yang ditunjukkan pada Persamaan 2.2. Hasil perhitungan ini berupa citra raster yang merepresentasikan tingkat perubahan vegetasi, terutama yang berkaitan dengan dampak kebakaran lahan dapat terlihat pada Gambar 3.6.

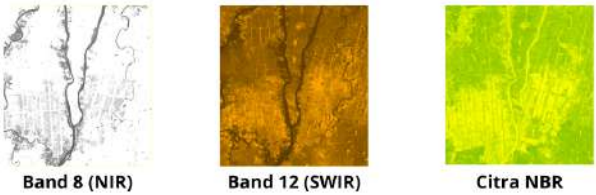

Gambar 3.6 Ilustrasi NBR

3.4.2.3 *Diferrence Normalized Burn Ratio (dNBR)*

Langkah selanjutnya ialah menghitung indeks dNBR (*delta Normalized Burn Ratio*) dengan menggunakan rumus yang tercantum pada Persamaan 2.3. Indeks ini berfungsi sebagai indikator untuk mengidentifikasi area yang terbakar. dNBR diperoleh dengan membandingkan nilai NBR dari citra sebelum kebakaran

(pra-kebakaran) dan setelah kebakaran (pasca-kebakaran). Proses ini dilakukan dengan menghitung nilai NBR untuk masing-masing kondisi pada setiap piksel, kemudian mencari selisihnya. Nilai selisih tersebut merepresentasikan perubahan vegetasi akibat kebakaran. Hasil akhir dari penghitungan ini divisualisasikan dalam bentuk citra raster yang menunjukkan tingkat keparahan dampak kebakaran pada vegetasi dapat terlihat pada Gambar 3.7.

Gambar 3.7 Ilustrasi dNBR

3.4.3 *Band Stacking*

Pada *band stacking* terdapat proses penggabungan beberapa kanal (band) spektral dari citra menjadi satu kesatuan citra *multiband*. Langkah ini penting karena memungkinkan model *deep learning* untuk menerima seluruh informasi spektral secara bersamaan dalam bentuk array multidimensi.

3.4.4 *Masking* Citra

Setelah didapatkan nilai dNBR dibuat sebuah *masking* citra atau citra *mask* biner (*ground truth*) untuk setiap lokasi. Citra *mask* ini berfungsi sebagai label atau kunci jawaban bagi model U-Net. Pada citra *mask* ini, piksel-piksel diberi nilai 1 untuk merepresentasikan area terbakar (*burned area*) dan nilai 0 untuk area tidak terbakar. Pembuatan *mask* ini menjadi acuan bagi model selama proses pelatihan untuk belajar membedakan kedua kelas tersebut.

3.4.5 Split Data

Data dibagi menjadi tiga bagian *training*, *validation*, dan *test data*. Pembagian ini memisahkan data untuk pelatihan model, evaluasi selama pelatihan, dan pengujian performa akhir model. Rasio pembagian data dibagi menjadi 60% - 80% untuk *training*, dan 10% - 20% untuk masing-masing *validation* dan *testing* data. Setelah melakukan split data akan dilakukan pengklasifikasian dengan model yang sudah ditentukan.

3.4.6 Model U-Net

Pada tahapan segmentasi *burned area* digunakan model berbasis arsitektur U-Net. Model U-Net yang digunakan memiliki arsitektur *encoder* (proses konvolusi dan *downsampling*) dan *decoder* (proses konvolusi, *upsampling* dan *skip connection*). Pada tahap *encoder*, citra *multiband* diproses melalui dua lapisan konvolusi 3×3 yang diikuti dengan operasi *max pooling*, bertujuan untuk mengurangi ukuran spasial dan mengekstraksi fitur. Setelah mencapai *bottleneck* (bagian tengah setelah proses *downsampling* selesai dan sebelum proses *upsampling* dimulai), fitur kemudian dikembalikan ke ukuran spasial semula melalui tahap *decoder* dengan proses *upsampling*. *Skip connection* dari lapisan *encoder* digunakan untuk mempertahankan informasi spasial yang penting. Proses ini diakhiri dengan lapisan konvolusi 1×1, sigmoid dan *thresholding* yang menghasilkan peta akhir, di mana setiap piksel diklasifikasikan dalam 2 *class* yaitu terbakar dan tidak terbakar. Arsitektur U-Net dalam penelitian ini juga dioptimalkan melalui penerapan beberapa *hyperparameter*, yaitu jumlah *epoch* untuk menentukan iterasi pelatihan, ukuran *batch size* untuk jumlah sampel yang diproses dalam satu iterasi, nilai *learning rate* sebagai kecepatan pembaruan bobot, serta penggunaan *optimizer* Adam yang secara adaptif menyesuaikan laju pembelajaran selama proses pelatihan. Arsitektur model U-Net yang digunakan dapat terlihat pada Gambar 3.8.

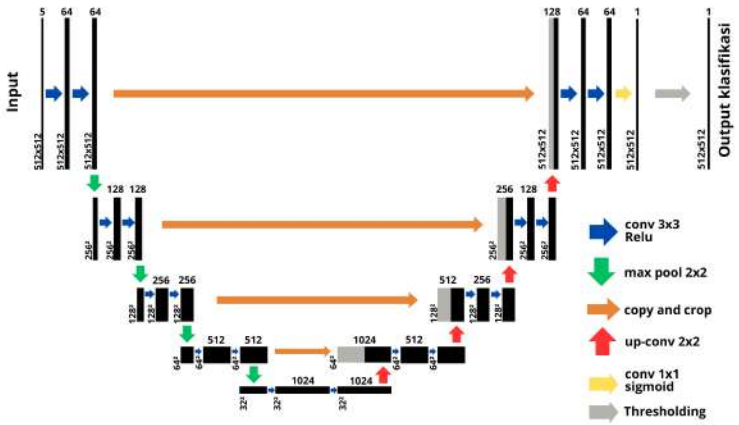

Gambar 3.8 Arsitektur Model U-Net

Tahapan proses dalam arsitektur model U-Net untuk segementasi citra dimulai dari input berupa matriks piksel, yang kemudian melewati tahap konvolusi dengan *padding same* dan aktivasi ReLU untuk mengekstraksi fitur penting dari citra. Setelah itu, dilakukan proses *max pooling* untuk mereduksi dimensi spasial dan mempertahankan informasi fitur utama. Hasil dari *pooling* ini kemudian diproses melalui *transpose convolution* untuk memperbesar kembali dimensi spasial citra. Pada tahap ini dilakukan juga *skip connection*, yaitu penggabungan antara hasil konvolusi awal dan hasil dari *transpose convolution* untuk mempertahankan informasi spasial dari level resolusi tinggi. Kemudian dilakukan konvolusi 1x1 untuk mereduksi dimensi kanal dan menghasilkan peta fitur akhir. Aktivasi sigmoid digunakan untuk mengubah hasil konvolusi menjadi nilai probabilistik antara 0 hingga 1 dan *thresholding* untuk mengubah nilai probabilitas menjadi biner(0 atau 1) berdasarkan ambang batas tertentu. Akhirnya, nilai tersebut diubah menjadi peta segmentasi biner pada tahap output, yang menunjukkan area terklasifikasi sesuai target. Tahapan yang terjadi bisa terlihat pada Gambar 3.9.

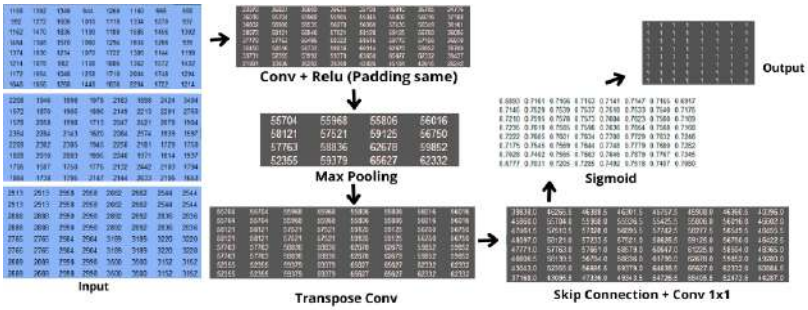

Gambar 3.9 Ilustrasi Model U-Net

3.4.7 Model Evaluasi

Setelah model U-Net menghasilkan *output*, dilakukan evaluasi kinerja secara komprehensif atau mencangkup banyak hal menggunakan metrik akurasi dan fungsi *loss* untuk mengukur keandalan segmentasi area terbakar. Kualitas prediksi dinilai menggunakan *Binary Accuracy* (Persamaan 2.4) yang menghitung proporsi piksel yang diklasifikasikan dengan benar, serta metrik spasial berupa *Intersection Over Union* (IoU) (Persamaan 2.5) dan *Dice Coefficient* (Persamaan 2.6) untuk mengukur tingkat kesesuaian atau tumpang tindih antara hasil prediksi dengan *ground truth*. Selain itu, untuk meminimalkan kesalahan selama proses pelatihan, digunakan *Binary Cross-Entropy* sebagai fungsi *loss* sesuai Persamaan 2.7 yang mengukur selisih distribusi probabilitas antara prediksi model dan label sebenarnya dalam klasifikasi biner.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Deskripsi Data

Penelitian ini memanfaatkan data citra satelit Sentinel-2 yang diperoleh melalui Google Earth Engine. Data Sentinel-2 menggunakan sistem penamaan tile berbasis *Military Grid Reference System* (MGRS), di mana setiap tile merepresentasikan area seluas sekitar 100 km $\times$ 100 km. Secara spesifik, lokasi penelitian difokuskan pada tiga tile yang berada pada Zona UTM 48 dan latitude band M, yaitu 48MUC, 48MVC, dan 48MWB. Ketiga tile tersebut dipilih karena secara spasial mencakup wilayah Sumatera Selatan yang merupakan salah satu daerah dengan tingkat kejadian kebakaran hutan dan lahan yang relatif tinggi. Wilayah ini didominasi oleh lahan gambut, perkebunan, dan semak belukar yang rentan mengalami kebakaran, terutama pada musim kemarau.

Pengambilan data citra dibagi menjadi dua kondisi, yaitu *prefire* (sebelum kebakaran) dan *postfire* (setelah kebakaran). Periode waktu untuk data *prefire* ditetapkan dari 1 Januari 2023 hingga 31 Juli 2023, sedangkan data postfire diambil dari 1 November 2023 hingga 31 Juli 2024, dengan pertimbangan puncak kebakaran terjadi pada rentang waktu 1 Agustus 2023 hingga 31 Oktober 2023. Guna memastikan kualitas data yang baik, pemilihan citra dilakukan dengan menerapkan kriteria tutupan awan di bawah 30%.

Tabel 4.1 menyajikan daftar citra yang tersedia untuk analisis kondisi *prefire* (sebelum kebakaran) dan *postfire* (sesudah kebakaran) pada tile 48MUC, 48MVC dan 48MWB. Informasi yang ditampilkan mencakup waktu akuisisi (pengambilan citra) dan persentase tutupan awan (*cloud cover*). *cloud cover* merupakan pesentase area citra satelit yang tertutup oleh awan pada saat perekaman citra, *cloud cover* tidak berasal bukan menunjukkan jenis awan, dan bukan menunjukkan kondisi cuaca harian melainkan indikator kualitas visual citra. *cloud cover* tidak berasal dari dataset, informasi *cloud cover* pada citra

Sentinel-2 diperoleh dari meta data citra yang dihitung secara otomatis berdasarkan algoritma deteksi awan, Sentinel-2 ini menyediakan nilai *cloud cover percentage* (CCP) di meta data produk. Setelah dilakukan seleksi berdasarkan nilai tutupan awan terendah, citra yang diakuisisi pada bulan Mei dan bulan Juni tahun 2023 sampai 2024 ditetapkan sebagai citra dengan persentase tutupan awan yang rendah.

Tabel 4.1 Daftar Citra Sentinel-2 Kondisi *Prefire* *Postfire*

Tile	**Kondisi**	**Tanggal Akuisisi Citra**	**Cloud Cover (%)**
48MUC	*Prefire*	2023-05-15	26.16
48MUC	*Postfire*	2024-07-25	0.00233
48MVC	*Prefire*	2023-05-22	32.01
48MVC	*Postfire*	2024-07-25	0.69
48MWB	*Prefire*	2023-07-13	5.10
48MWB	*Postfire*	2024-07-25	4.29

Data band utama digunakan pada penelitian ini adalah band 4, band 8, band 11 dan band 12. Band tersebut telah dikonversi ke dalam bentuk reflektansi BOA (*Bottom of Atmosphere*) dalam skala 0 hingga 10000 (*digital number*) sehingga dilakukan perubahan agar skala berada pada 0 hingga 1. Data yang digunakan di dapat atau diakses melalui Google Earth Engine yang telah dilakukan koreksi radiometrik dan geometrik. Analisis distribusi reflektansi pada setiap band dilakukan untuk memahami karakteristik spektral objek permukaan bumi serta mengevaluasi kemampuan masing-masing band dalam membedakan area terbakar dan tidak terbakar. Perbedaan distribusi reflektansi antara kondisi *prefire* dan *postfire* menunjukkan adanya perubahan fisik pada permukaan lahan akibat kebakaran. Informasi ini menjadi dasar dalam pemilihan band dan indeks spektral yang digunakan sebagai input model, serta untuk memastikan kualitas dan konsistensi data sebelum proses pelatihan model *deep learning*. Pada gambar 4.1 menunjukkan gambar distribusi reflektansi pada masing-masing tile dari kondisi *prefire* hingga kondisi *postfire*.

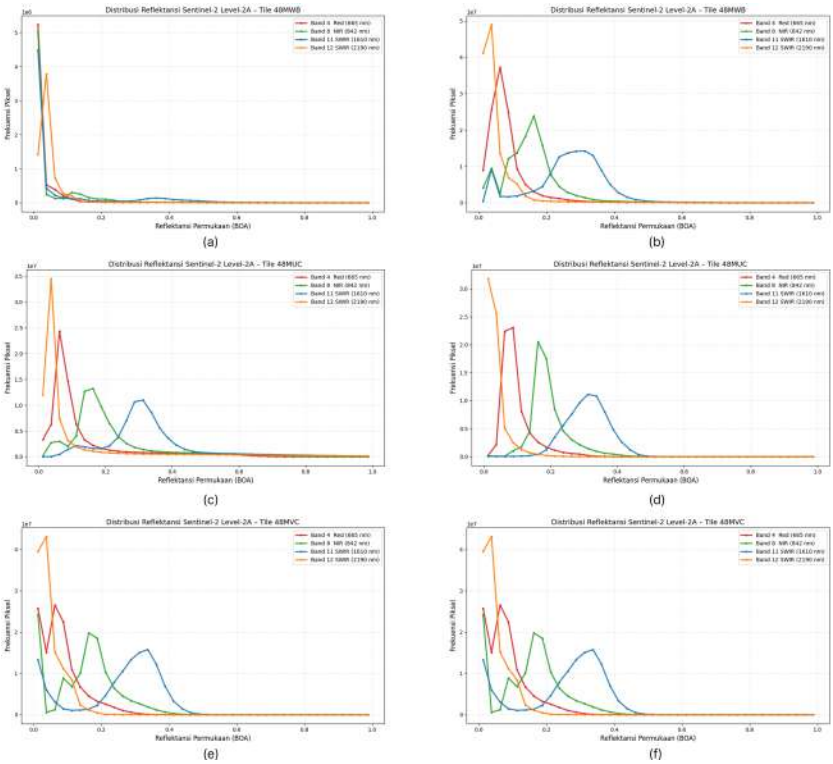

Gambar 4.1 Distribusi Reflektansi Pada Tiap Tile, (a).Tile 48MWB *Prefire* (b).Tile 48MWB *Postfire* (c).Tile 48MUC *Prefire* (d).Tile 48MUC *Postfire* (e).Tile 48MVC *Prefire* (f).Tile 48MVC *Postfire*.

Distribusi frekuensi piksel terhadap reflektansi permukaan (BOA) dari citra Sentinel-2 Level-2A untuk (a).tile 48MWB pada kondisi *prefire* (sebelum kebakaran), menunjukkan pola yang konsisten pada band inframerah gelombang pendek (SWIR). Band 12 (SWIR 2190 nm) dan Band 11 (SWIR 1610 nm) sama-sama menunjukkan puncak frekuensi tertinggi pada nilai reflektansi yang sangat rendah (sekitar 0.05). Hal ini mengindikasikan dominasi objek dengan daya serap air tinggi, seperti badan air atau vegetasi dengan kadar air tinggi, karena air menyerap kuat gelombang SWIR. Sementara itu, Band 8 (NIR) dan Band 4 (Red) menunjukkan pola vegetasi sehat, di mana reflektansi NIR lebih tinggi dibandingkan Red, menandakan aktivitas klorofil yang baik.

Distribusi frekuensi piksel terhadap reflektansi permukaan (BOA) dari

citra Sentinel-2 Level-2A untuk (b). tile 48MWB pada kondisi *postfire* (sesudah kebakaran), menunjukkan perubahan drastis. Band 12 (SWIR 2190 nm) tetap mempertahankan puncak tajam pada reflektansi rendah (0.05), yang kemungkinan mewakili area basah atau perairan yang tidak terbakar. Namun, perbedaan signifikan terlihat pada Band 11 (SWIR 1610 nm) yang distribusinya melebar ke arah nilai reflektansi yang lebih tinggi (0.2 - 0.4), terpisah dari pola Band 12. Fitur paling menonjol adalah lonjakan Band 4 (Red) yang kini memiliki frekuensi puncak lebih tinggi dibanding Band 8 (NIR). Fenomena *crossover* di mana reflektansi Red menjadi lebih dominan daripada NIR, disertai peningkatan reflektansi pada Band 11, adalah tanda spektral khas area bekas terbakar (*burn scar*) di mana vegetasi hilang dan tanah kering atau abu terekspos.

Distribusi frekuensi piksel terhadap reflektansi permukaan (BOA) dari citra Sentinel-2 Level-2A untuk (c).tile 48MUC pada kondisi *prefire* (sebelum kebakaran), memperlihatkan separasi spektral yang jelas. Band 12 (SWIR 2190 nm), menunjukkan puncak yang sangat tajam dan tinggi pada reflektansi rendah (0.05), berimpit dengan Band 11 (SWIR 1610 nm). Ini mengonfirmasi keberadaan area non-vegetasi basah atau bayangan. Karakteristik vegetasi sehat sangat dominan, ditandai dengan distribusi Band 8 (NIR) yang melebar pada rentang reflektansi tinggi (0.3 - 0.35), jauh di atas distribusi Band 4 (Red) yang berada di rentang rendah (0.15). Pola ini menunjukkan tutupan lahan didominasi oleh biomassa hijau yang sehat sebelum kejadian kebakaran.

Distribusi frekuensi piksel terhadap reflektansi permukaan (BOA) dari citra Sentinel-2 Level-2A untuk (d).tile 48MUC pada kondisi *postfire* (sesudah kebakaran), mengalami pergeseran. Band 12 (SWIR 2190 nm) masih mendominasi di nilai reflektansi rendah, namun Band 11 (SWIR 1610 nm) terlihat memiliki ekor distribusi yang menjulur ke nilai reflektansi yang lebih tinggi, mengindikasikan respons spektral tanah terbuka yang kering. Perubahan paling kritikal terlihat pada Band 4 (Red) yang mengalami lonjakan intensitas frekuensi yang sangat tajam pada nilai reflektansi sekitar 0.18 - 0.2, melampaui

intensitas Band 8 (NIR). Hilangnya penyerapan klorofil pada Band Merah dan penurunan pantulan pada NIR ini mengonfirmasi kerusakan vegetasi yang luas akibat api.

Distribusi frekuensi piksel terhadap reflektansi permukaan (BOA) dari citra Sentinel-2 Level-2A untuk (e).tile 48MVC pada kondisi *prefire* (sebelum kebakaran), Band 12 (SWIR 2190 nm) kembali menunjukkan karakteristik penyerapan kuat dengan puncak frekuensi ekstrem di nilai reflektansi 0.05, serupa dengan Band 11 (SWIR 1610 nm). Tingginya frekuensi pada nilai rendah ini mengindikasikan proporsi badan air atau lahan basah yang signifikan di dalam tile. Vegetasi sehat teridentifikasi jelas melalui jarak (separasi) yang lebar antara puncak Band 8 (NIR) di reflektansi tinggi (0.4) dan Band 4 (Red) di reflektansi rendah (0.2)

Distribusi frekuensi piksel terhadap reflektansi permukaan (BOA) dari citra Sentinel-2 Level-2A untuk (f).tile 48MVC pada kondisi *postfire* (sesudah kebakaran), menunjukkan memperlihatkan dampak kebakaran yang nyata. Meskipun Band 12 (SWIR 2190 nm) tetap memiliki puncak stasioner di nilai rendah (indikasi area tak terbakar/air), Band 11 (SWIR 1610 nm) menunjukkan pelebaran distribusi ke arah nilai yang lebih tinggi. Indikator utama kebakaran terlihat pada pergeseran Band 4 (Red) yang membentuk puncak baru yang sangat dominan dan tajam pada reflektansi 0.18 - 0.2. Dominasi reflektansi Band 4 terhadap Band 8, serta divergensi antara perilaku Band 11 dan Band 12, memperkuat identifikasi area bekas kebakaran yang menyisakan abu atau tanah kering di permukaan.

4.2 *Praprocessing Data*

Tahap prapemrosesan data bertujuan untuk mengoreksi dan membersihkan citra Sentinel-2 dari berbagai gangguan seperti bayangan awan dan awan sehingga citra menjadi layak untuk dianalisis lebih lanjut. Proses ini mencakup beberapa tahapan sebagai berikut.

4.2.1 *Cloud Masking*

Cloud masking Merupakan langkah prapemrosesan untuk memastikan akurasi analisis data citra satelit. Langkah ini bertujuan untuk mengurangi dan mengeliminasi pengaruh dari awan, sirus (awan tipis), dan bayangan awan yang dapat mengganggu interpretasi spasial maupun spektral. Awan, yang umumnya memiliki reflektansi tinggi, serta bayangannya, yang memiliki reflektansi sangat rendah, dapat menyebabkan ketidakakuratan yang besar dalam perhitungan indeks spektral, seperti indeks vegetasi (NDVI) maupun indeks area terbakar (seperti NBR). Kesalahan interpretasi ini dapat terjadi, di mana awan dapat salah terdeteksi sebagai permukaan non-vegetasi atau bayangan awan dapat keliru dianggap sebagai badan air atau bahkan area terbakar.

Oleh karena itu, mengidentifikasi dan menutupi (*masking*) piksel-piksel yang terkontaminasi ini menjadi bagian penting dalam alur kerja penelitian sebelum dilakukan analisis lebih lanjut. Dalam penelitian ini, proses *cloud masking* diterapkan pada citra Sentinel-2 Level-2A dengan memanfaatkan data SCL (*Scene Classification Layer*). Band SCL merupakan produk klasifikasi yang sudah disediakan oleh ESA (*European Space Agency*) yang mengkategorikan setiap piksel ke dalam kelas-kelas tertentu, seperti vegetasi, tanah, air, awan, sirus, dan bayangan awan. Masking dilakukan dengan menyaring dan menghilangkan semua piksel yang oleh SCL diklasifikasikan sebagai awan (baik kepadatan tinggi, sedang, maupun rendah), sirus, dan bayangan awan dengan hanya mengambil vegetasi, tanah terbuka dan air. Pembagian kelas SCL dapat terlihat pada tabel 4.2.

Tabel 4.2 Kelas *Scene Classification Layer* (SCL) Sentinel-2

Kode SCL	Kelas	Keterangan
0	No Data	Piksel tidak terdefinisi
1	Saturated / Defective	Piksel rusak
2	Dark Area Pixels	Area gelap
3	Cloud Shadows	Bayangan awan
4	Vegetation	Vegetasi
5	Bare Soils	Tanah terbuka
6	Water	Badan air
7	Unclassified	Tidak terklasifikasi
8	Cloud Medium Probability	Awan sedang
9	Cloud High Probability	Awan tinggi
10	Thin Cirrus	Awan tipis
11	Snow or Ice	Salju atau es

Dengan demikian, hanya piksel yang merepresentasikan permukaan tanah aktual (seperti vegetasi, tanah terbuka, air, atau area urban) yang dipertahankan untuk tahap analisis selanjutnya, sehingga memastikan bahwa data yang digunakan bebas dari distorsi atmosferik (perubahan atau gangguan pada cahaya, sinyal, atau penglihatan yang terjadi karena kondisi udara/atmosfer). Pada Gambar 4.2 menunjukkan hasil visualisasi citra setelah proses *cloud masking* diterapkan pada ketiga tile penelitian (48MUC, 48MVC, dan 48MWB). Kolom (a) menampilkan citra pada kondisi *prefire* dan kolom (b) menampilkan citra pada kondisi *postfire*. Citra ditampilkan dalam komposit *false color* (kemungkinan kombinasi band SWIR, NIR, dan Red), di mana vegetasi sehat tampak berwarna hijau cerah, sedangkan area terbakar (terlihat jelas pada citra *postfire* 48MWB dan 48MUC) tampak berwarna merah muda atau oranye.

Dapat diamati, misalnya pada citra Tile 48MUC *prefire* (a), bahwa area di luar batas tile serta beberapa piksel yang teridentifikasi sebagai

awan telah berhasil dihilangkan (ditampilkan sebagai area putih/transparan). Demikian pula pada Tile 48MWB *prefire* (a), tutupan awan tipis di bagian kiri bawah dan kanan atas dapat dideteksi oleh SCL. Proses ini memastikan bahwa piksel-piksel yang terkontaminasi tersebut tidak akan salah diinterpretasikan sebagai perubahan permukaan pada tahapan analisis deteksi kebakaran.

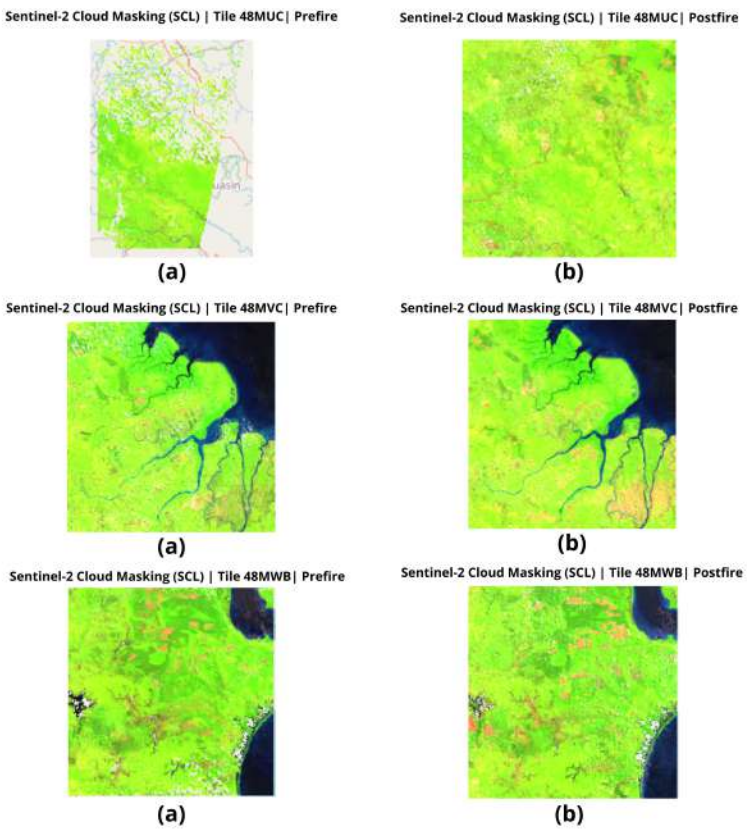

Gambar 4.2 *Cloud Masking* (SCL) Pada Kondisi *Prefire* dan *Postfire*

4.2.2 Komposit Citra

Proses komposit citra dilakukan dengan menggabungkan beberapa band spektral Sentinel-2 ke dalam satu citra multi-kanal yang berfungsi sebagai input bagi model segmentasi. Pada penelitian ini, digunakan komposit *False Color* (warna semu) dengan kombinasi Band 11 (SWIR), Band 8 (NIR), dan Band 4 (Red), di mana

masing-masing band dipetakan ke kanal RGB. Berbeda dengan *true color* yang merepresentasikan warna alami untuk interpretasi visual manusia, komposit *false color* dirancang khusus untuk menonjolkan perbedaan karakteristik spektral objek di permukaan bumi. Penggunaan band NIR dan SWIR pada komposit ini memungkinkan area terbakar dan vegetasi rusak dapat ditampilkan dengan kontras yang lebih jelas dibandingkan *true color*, sehingga dinilai lebih efektif sebagai input model U-Net. Hal ini diperkuat oleh hasil penelitian [19], yang menunjukkan bahwa segmentasi citra menggunakan U-Net pada input komposit *false color* memiliki nilai akurasi, *Intersection over Union* (IoU), dan *Dice Coefficient* yang lebih unggul dibandingkan dengan penggunaan komposit *natural color*.

4.3 Ekstraksi Fitur

4.3.1 *Normalized Difference Vegetation Index* (NDVI)

Pada gambar 4.3 ditunjukkan perbandingan histogram nilai NDVI untuk Tile 48MWB antara kondisi (a) *prefire* dan (b) *postfire*. Pada kondisi *prefire*, distribusi nilai NDVI menunjukkan konsentrasi yang sangat ekstrem dan terpusat pada nilai positif tinggi. Puncak frekuensi tertinggi dan paling dominan terdapat pada rentang 0.85 hingga 0.90. Distribusi yang sangat terkonsentrasi pada nilai NDVI sangat tinggi ini mengindikasikan bahwa hampir seluruh wilayah citra pada kondisi *prefire* didominasi oleh vegetasi yang sangat sehat, rapat, dan seragam. Frekuensi piksel untuk rentang nilai negatif (merepresentasikan badan air) dan rentang positif-rendah (tanah terbuka) terlihat hampir nol. Setiap piksel menghasilkan 1 nilai NDVI dalam rentang 1 sampai +1 yang nantinya rentang NDVI 0.85–0.90 diperoleh dari hasil perhitungan NDVI per piksel. Pada kondisi *postfire*, distribusi nilai NDVI menunjukkan kecenderungan yang masih sangat kuat ke arah nilai positif tinggi. Puncak frekuensi tertinggi dan paling dominan terdapat pada rentang 0.80 hingga 0.85. Distribusi yang sangat terkonsentrasi pada nilai NDVI tinggi ini mengindikasikan bahwa sebagian besar wilayah citra pada kondisi *postfire* ini masih didominasi oleh vegetasi yang sehat dan lebat. Selain itu, terdapat juga puncak

sekunder yang lebih kecil namun jelas pada rentang nilai negatif, khususnya di sekitar -0.45 hingga -0.35. Nilai NDVI negatif ini secara khas merepresentasikan area non-vegetasi seperti badan air atau kemungkinan area bayangan. Sementara itu, frekuensi piksel pada rentang NDVI rendah-positif (sekitar 0.1 hingga 0.3), yang umumnya diasosiasikan dengan tanah terbuka atau area terbakar, terlihat relatif sangat kecil. Hal ini menandakan bahwa pada kondisi *postfire* ini, area citra didominasi oleh vegetasi sehat dan badan air, dengan tutupan area terbakar yang terdeteksi minimal.

Histogram (c) dan (d) menunjukkan perbandingan nilai NDVI untuk Tile 48MUC antara kondisi (c) *prefire* dan (d) *postfire*, pada histogram (c) distribusi nilai NDVI menunjukkan konsentrasi yang sangat kuat dan dominan pada nilai positif tinggi. Puncak frekuensi tertinggi terdapat pada rentang 0.85 hingga 0.90 serta pada rentang 0.80 hingga 0.85 juga menunjukkan frekuensi tinggi. Distribusi yang sangat terkonsentrasi pada nilai NDVI sangat tinggi ini mengindikasikan bahwa sebagian besar wilayah citra pada kondisi *prefire* didominasi oleh vegetasi yang sangat sehat dan lebat. Frekuensi piksel untuk rentang nilai negatif (merepresentasikan badan air) dan rentang positif-rendah (tanah terbuka) terlihat sangat minim dan mendekati nol. Pada histogram (d) menunjukkan pola yang hampir identik dengan kondisi *prefire*, dengan kecenderungan yang juga sangat kuat ke arah nilai positif tinggi. Puncak frekuensi tertinggi dan paling dominan masih terdapat pada rentang 0.85 hingga 0.90. Distribusi yang sangat terkonsentrasi ini kembali mengindikasikan bahwa sebagian besar wilayah citra pada kondisi *postfire* masih didominasi oleh vegetasi yang sehat dan lebat. Sama seperti kondisi *prefire*, tidak terdapat puncak sekunder yang jelas pada rentang nilai negatif (badan air) ataupun rentang positif-rendah (area terbakar), yang frekuensinya terlihat sangat kecil. Hal ini menandakan bahwa pada tile ini, tutupan lahan dominan tetap berupa vegetasi sehat, dan tidak terdeteksi adanya dampak kebakaran yang signifikan atau perubahan besar pada tutupan lahan lainnya.

Histogram (e) dan (f) meunjukkan perbandingan histogram nilai NDVI

untuk Tile 48MVC antara kondisi (e) *prefire* dan (f) *postfire*. Pada histogram (e) distribusi nilai NDVI menunjukkan karakteristik bimodal (dua puncak). Puncak pertama yang paling dominan berada pada rentang nilai positif tinggi, yaitu 0.80 hingga 0.85. Puncak ini mengindikasikan dominasi vegetasi yang sangat sehat dan lebat. Selain itu, terdapat puncak sekunder yang jelas pada rentang nilai negatif, terkonsentrasi di antara -0.55 hingga -0.40, dengan puncak di sekitar -0.50. Puncak negatif ini secara khas merepresentasikan tutupan lahan non-vegetasi seperti badan air atau awan/bayangan. Sementara itu, frekuensi piksel pada rentang NDVI positif-rendah (0.1-0.3), yang diasosiasikan dengan tanah terbuka, terlihat sangat minimal. Pada histogram (f) distribusi nilai NDVI mengalami perubahan signifikan menjadi unimodal (satu puncak). Puncak sekunder pada nilai negatif yang terlihat di kondisi *prefire* kini telah menghilang, dengan frekuensi pada rentang tersebut turun mendekati nol. Distribusi kini sepenuhnya didominasi oleh puncak nilai positif tinggi pada rentang 0.80 hingga 0.85. Hal ini mengindikasikan bahwa pasca-kebakaran, citra didominasi penuh oleh vegetasi sehat. Hilangnya puncak negatif menunjukkan bahwa area badan air atau awan/bayangan yang terdeteksi sebelumnya sudah tidak ada pada citra *postfire*. Sama seperti kondisi *prefire*, sinyal untuk area terbakar (0.1-0.3) tetap terdeteksi sangat minimal.

NDVI digunakan pada tahap eksraksi fitu karena mampu mempresentasikan kondisi dan kerapatan vegetasi secara kantitatif, sehingga perubahan vegetasi akbiat kabakaran dapat terlihat lebih jelas. Histogram persebaran *Normalized Difference Vegetation Index* (NDVI) digunakan untuk menggambarkan distribusi nilai NDVI pada seluruh piksel citra di wilayah penelitian. Melalui histogram ini, karakteristik kondisi vegetasi dapat dianalisis secara kuantitatif dan menyeluruh.

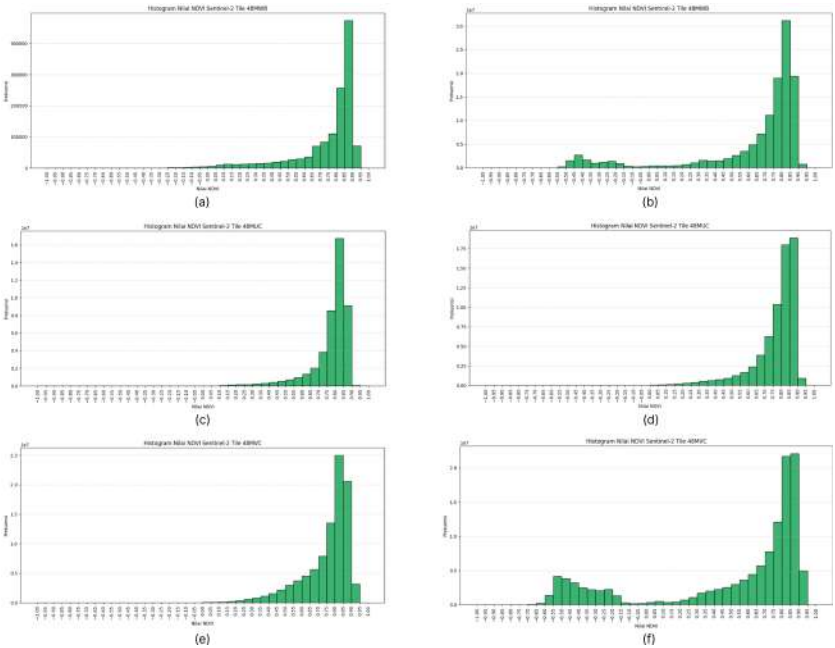

Gambar 4.3 Histogram NDVI Pada Tiap Tile, (a).Tile 48MWB *Prefire* (b).Tile 48MWB *Postfire* (c).Tile 48MUC *Prefire* (d).Tile 48MUC *Postfire* (e).Tile 48MVC *Prefire* (f).Tile 48MVC *Postfire*.

4.3.2 *Normalized Burn Ratio* (NBR)

Pada gambar 4.4 ditunjukkan perbandingan histogram nilai NBR untuk Tile 48MWB antara kondisi (a) *prefire* dan (b) *postfire*. Histogram (a) distribusi nilai NBR menunjukkan karakteristik unimodal (satu puncak) yang sangat tajam dan dominan. Puncak frekuensi tertinggi ini terkonsentrasi pada rentang nilai NBR positif yang sangat tinggi, yaitu antara 0.70 hingga 0.80. Distribusi yang sangat terpusat ini mengindikasikan bahwa kondisi *prefire* didominasi oleh lanskap yang sangat seragam (homogen), yang merepresentasikan vegetasi sehat, lebat, dan memiliki kelembaban tinggi. Frekuensi piksel pada rentang nilai NBR yang lebih rendah (mendekati nol atau negatif), yang dapat diasosiasikan dengan tanah terbuka atau vegetasi tertekan, terlihat sangat minimal.

Pada histogram (b) untuk kondisi *postfire*, distribusi nilai NBR mengalami perubahan signifikan dan kini menunjukkan karakteristik

bimodal (dua puncak). Puncak dominan kini telah bergeser ke nilai yang sedikit lebih rendah, berpusat pada rentang 0.60 hingga 0.70, yang mengindikasikan bahwa vegetasi sehat masih menjadi tutupan lahan mayoritas. Namun, dampak kebakaran terlihat jelas dengan munculnya puncak sekunder baru pada rentang NBR positif-rendah, khususnya terkonsentrasi di sekitar 0.05 hingga 0.10. Munculnya puncak pada nilai NBR rendah ini merupakan indikator kuat adanya area terbakar, di mana vegetasi telah hilang atau mengering. Dengan demikian, histogram *postfire* menunjukkan kondisi lanskap yang campuran (heterogen), yang terdiri dari area vegetasi sehat yang tidak terbakar dan area baru yang terdampak oleh api.

Pada histogram (c) dan (d) ditunjukkan perbandingan histogram nilai NBR untuk Tile 48MUC antara kondisi (c) *prefire* dan (d) *postfire*. Histogram (c) *prefire*, distribusi nilai NBR menunjukkan karakteristik unimodal (satu puncak) yang sangat tajam dan dominan. Puncak frekuensi tertinggi ini terkonsentrasi pada rentang nilai NBR positif tinggi, yaitu berpusat kuat di antara 0.60 hingga 0.70. Distribusi yang sangat terpusat ini mengindikasikan bahwa kondisi *prefire* didominasi secara seragam (homogen) oleh vegetasi yang sehat dan memiliki kelembaban tinggi.

Pada histogram (d) untuk kondisi *postfire*, distribusi nilai NBR terlihat hampir identik dan tidak menunjukkan perubahan yang signifikan dibandingkan dengan kondisi *prefire*. Distribusi masih tetap sangat unimodal, dengan puncak dominan yang juga berpusat di rentang 0.60 hingga 0.70. Tidak terlihat adanya pembentukan puncak sekunder baru pada rentang NBR positif-rendah (misalnya, di sekitar 0.05-0.10), yang merupakan indikator khas untuk area terbakar. Kemiripan yang sangat tinggi antara kedua histogram ini menandakan bahwa wilayah yang dicakup oleh Tile 48MUC kemungkinan besar tidak terdampak secara signifikan oleh peristiwa kebakaran tersebut, dan lanskap masih didominasi penuh oleh vegetasi sehat.

Pada histogram (e) dan (f) ditunjukkan perbandingan histogram nilai NBR untuk Tile 48MVC antara kondisi (e) *prefire* dan (f) *postfire*.

Histogram (e) *prefire*, distribusi nilai NBR menunjukkan karakteristik unimodal (satu puncak) yang sangat tajam dan sangat dominan. Puncak frekuensi tertinggi ini terkonsentrasi pada rentang nilai NBR positif tinggi, yaitu berpusat kuat di sekitar 0.60 hingga 0.70. Distribusi yang sangat terpusat ini mengindikasikan bahwa kondisi *prefire* didominasi oleh lanskap yang sangat seragam (homogen), yang merepresentasikan vegetasi sehat dengan kelembaban tinggi.

Pada histogram (f) untuk kondisi *postfire*, distribusi nilai NBR mengalami perubahan yang sangat signifikan dan kini menunjukkan karakteristik bimodal (dua puncak) yang jelas. Puncak pertama, yang mewakili vegetasi sehat yang tidak terbakar, masih terlihat dominan pada rentang 0.60 hingga 0.70. Namun, dampak kebakaran terlihat jelas dengan munculnya puncak sekunder baru yang sangat jelas pada rentang NBR positif-rendah, yang terkonsentrasi di antara 0.15 hingga 0.30. Munculnya puncak baru pada nilai NBR rendah ini merupakan indikator kuat adanya area terbakar yang signifikan, di mana vegetasi telah rusak atau hilang dan tergantikan oleh tanah terbuka atau abu sisa kebakaran. Dengan demikian, histogram *postfire* menunjukkan transformasi lanskap dari seragam menjadi campuran (heterogen), yang kini terdiri dari area vegetasi sehat yang tidak terbakar dan area baru yang terdampak oleh api.

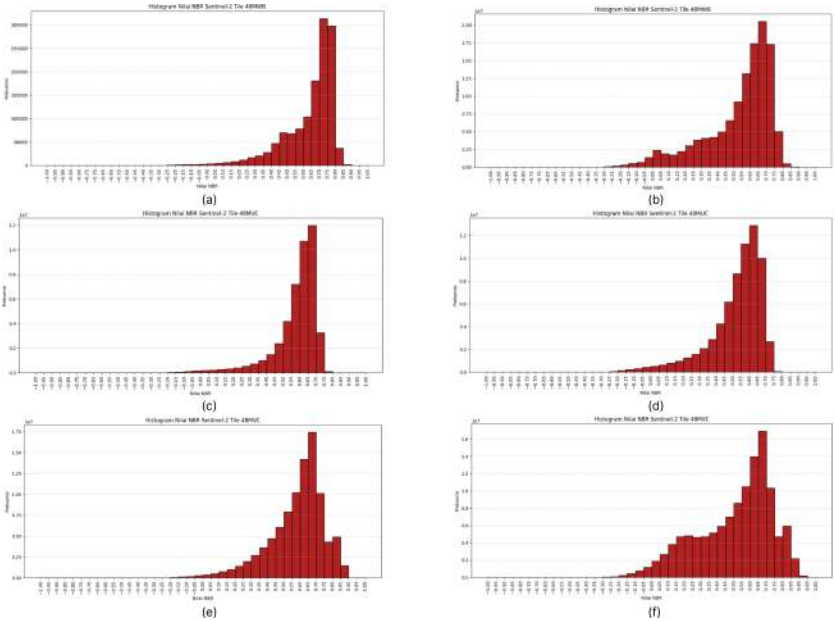

Gambar 4.4 Histogram NBR Pada Tiap Tile, (a).Tile 48MWB *Prefire* (b).Tile 48MWB *Postfire* (c).Tile 48MUC *Prefire* (d).Tile 48MUC *Postfire* (e).Tile 48MVC *Prefire* (f).Tile 48MVC *Postfire*.

4.3.3 *Difference Normalized Burn Ratio* (dNBR)

Pada gambar 4.5 menunjukan dNBR pada (a) Tile 48MWB,distribusi nilai memperlihatkan konsentrasi yang sangat kuat dan tajam di sekitar nilai nol, dengan puncak frekuensi tertinggi berada pada kisaran -0.05 hingga 0.00. Sebaran yang sangat terpusat ini mengindikasikan bahwa sebagian besar wilayah citra tidak mengalami perubahan vegetasi yang signifikan antara citra *prefire* dan *postfire*, atau dengan kata lain, area tersebut tidak terbakar. Meskipun demikian, histogram juga menunjukkan adanya sebaran nilai dNBR positif, yang menandakan terdeteksinya area yang terdampak kebakaran. Walaupun terdapat piksel dengan nilai dNBR di atas 0.10 (yang mengindikasikan keparahan kebakaran), frekuensinya jauh lebih rendah dibandingkan dengan puncak tidak berubah. Secara khusus, frekuensi untuk keparahan kebakaran tinggi (misalnya, dNBR > 0.60) terlihat sangat kecil, yang menunjukkan bahwa area yang terbakar parah tidak dominan di tile ini.

pada Tile (b) 48MUC distribusi nilai memperlihatkan konsentrasi yang sangat tinggi dan tajam yang berpusat tepat di sekitar nilai nol. Puncak frekuensi tertinggi dan paling dominan berada pada kisaran 0.00 hingga 0.05. Sebaran yang sangat terpusat ini mengindikasikan bahwa sebagian besar wilayah citra tidak mengalami perubahan vegetasi yang signifikan antara citra *prefire* dan *postfire*, atau dengan kata lain, area tersebut tidak terbakar. Meskipun histogram menunjukkan adanya sebaran nilai dNBR positif (nilai > 0.10), frekuensinya sangat kecil dan tidak signifikan jika dibandingkan dengan puncak masif di sekitar nol. Hal ini menunjukkan bahwa keparahan kebakaran di seluruh tile ini dapat dikategorikan sebagai sangat rendah atau hampir tidak ada.

Lalu pada pada (c) Tile 48MVC distribusi nilai menunjukkan konsentrasi yang sangat tinggi dan tajam yang berpusat tepat di sekitar nilai nol. Puncak frekuensi tertinggi dan paling dominan berada pada kisaran 0.00 hingga 0.05. Sebaran yang sangat terpusat ini mengindikasikan bahwa sebagian besar wilayah citra tidak mengalami perubahan vegetasi yang signifikan antara citra *prefire* dan *postfire*, yang menunjukkan bahwa area tersebut sebagian besar tidak terbakar. Meskipun histogram menunjukkan adanya sebaran nilai dNBR positif (nilai > 0.10) yang mengindikasikan adanya keparahan kebakaran, frekuensinya terlihat sangat kecil dan tidak signifikan jika dibandingkan dengan puncak masif di sekitar nol. Hal ini menegaskan bahwa area yang terdampak kebakaran di tile ini sangat terbatas.

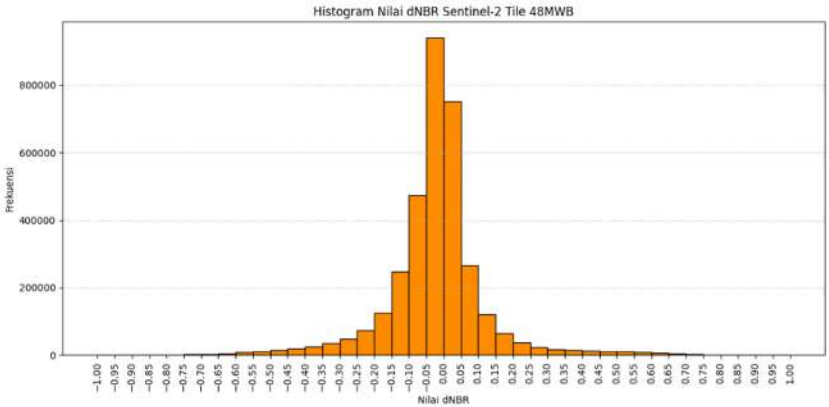

(a)

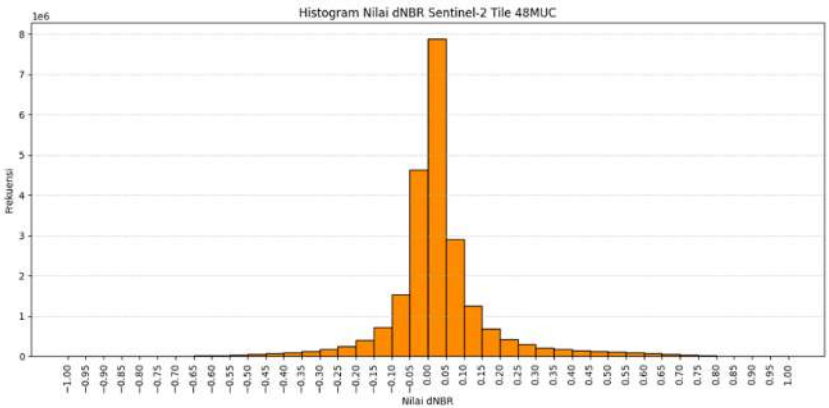

(b)

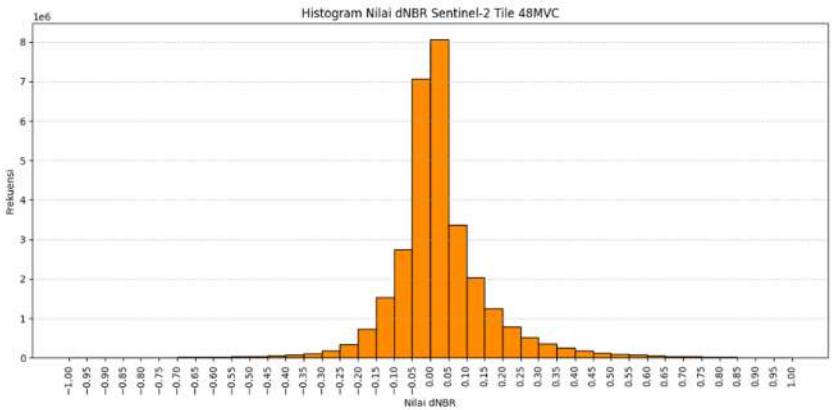

(c)

Gambar 4.5 Histogram dNBR Untuk (a).Tile 48MWB (b).Tile 48MUC dan (c).Tile 48MVC

4.4 *Masking* Citra

Pada gambar 4.6 menunjukkan distribusi frekuensi piksel pada citra mask (hasil segmentasi) untuk Tile 48MWB. Berdasarkan grafik batang tersebut, terlihat bahwa frekuensi piksel yang diklasifikasikan sebagai *Burned* (1) adalah sebanyak 2.913.310 piksel. Sementara itu, area yang diklasifikasikan sebagai *Unburned* (0) jauh lebih dominan, mencakup 24.171.440 piksel dari keseluruhan area tile yang dianalisis. *Burned area* merupakan wilayah atau piksel yang merepresentasikan area yang terdampak kebakaran sedangkan *unburned area* mempresentasikan wilayah atau piksel yang tidak terdampak kebakaran.

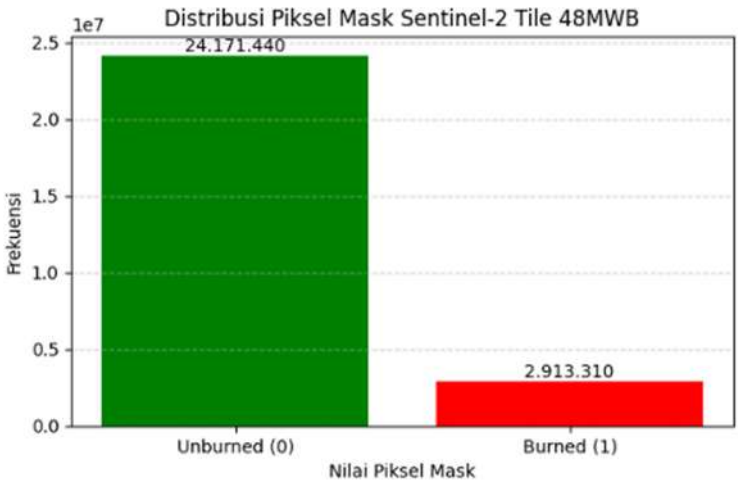

Gambar 4.6 Disribusi Piksel Citra *mask* Tile 48MWB

Pada gambar 4.7 menunjukkan distribusi frekuensi piksel pada citra mask (hasil segmentasi) untuk Tile 48MUC. Berdasarkan grafik batang tersebut, terlihat bahwa frekuensi piksel yang diklasifikasikan sebagai *Burned* (1) adalah sebanyak 14.785.420 piksel. Sementara itu, area yang diklasifikasikan sebagai *Unburned* (0) jauh lebih dominan, mencakup 74.518.106 piksel dari keseluruhan area tile yang dianalisis.

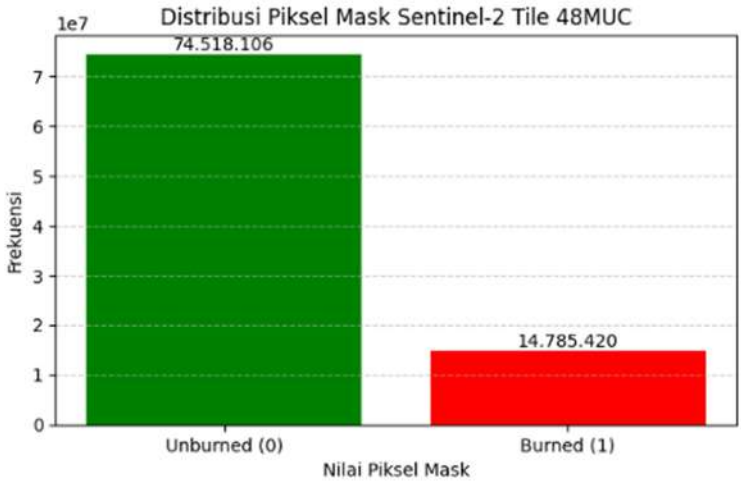

Gambar 4.7 Disribusi Piksel Citra *mask* Tile 48MUC

Pada gambar 4.8 ditunjukkan distribusi frekuensi piksel pada citra mask (hasil segmentasi) untuk Tile 48MVC. Berdasarkan grafik batang tersebut, terlihat bahwa frekuensi piksel yang diklasifikasikan sebagai *Burned* (1) adalah sebanyak 23.839.592 piksel. Sementara itu, area yang diklasifikasikan sebagai *Unburned* (0) jauh lebih dominan, mencakup 97.831.282 piksel dari keseluruhan area tile yang dianalisis.

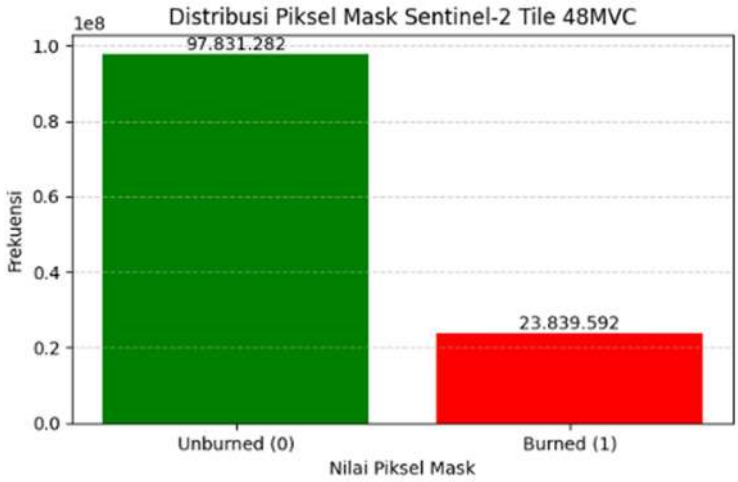

Gambar 4.8 Disribusi Piksel Citra *mask* Tile 48MVC

Distribusi jumlah piksel pada data *mask* kelas *Unburned Area* dan

Burned Area menunjukkan bahwa jumlah piksel kelas *Unburned Area* jauh lebih dominan dibandingkan kelas *Burned Area*. Distribusi ini mengonfirmasi adanya ketidakseimbangan kelas pada dataset. Kondisi ini menjelaskan mengapa model mampu mencapai nilai akurasi dan *Binary Cross Entropy* yang relatif baik, namun menunjukkan nilai IoU dan *Dice* yang lebih moderat, karena kedua metrik tersebut lebih sensitif terhadap performa pada kelas minoritas.

4.5 *Band Stacking*

Proses *band stacking* pada penelitian ini dilakukan untuk citra Sentinel-2 kondisi *postfire*, yang selanjutnya digunakan sebagai data masukan (input) dalam pelatihan model segmentasi U-Net. Tujuan utama dari *band stacking* adalah membentuk citra *multiband* yang menggabungkan informasi spektral dan indeks-indeks relevan ke dalam satu representasi data. Dalam hal ini, lima kanal (5 band) yang digunakan adalah Band 4 (Red), Band 8 (NIR), Band 11 (SWIR), serta hasil kalkulasi NDVI, dan NBR. Proses kalkulasi NDVI dihitung menggunakan rasio ter-normalisasi antara band inframerah dekat (B8) dan band merah (B4), sedangkan NBR dihitung menggunakan rasio ter-normalisasi antara band inframerah dekat (B8) dan band inframerah gelombang pendek (B11). Selanjutnya, band reflektansi B4, B8, B11 serta hasil perhitungan NDVI dan NBR digabungkan melalui proses *band stacking* untuk membentuk citra *multiband* yang digunakan sebagai input model U-Net. *Band stacking* ini dilakukan terhadap citra pada setiap tile penelitian (48MWB, 48MUC, dan 48MVC), yang sebelumnya telah melalui proses *cloud masking* menggunakan SCL. Dengan menyatukan kelima kanal ini, model U-Net dapat memanfaatkan tidak hanya informasi reflektansi mentah dari kanal Sentinel-2, tetapi juga informasi turunan yang krusial, sehingga diharapkan dapat memperkuat kemampuan model dalam membedakan antara area vegetasi sehat dan area terbakar.

4.6 *Split Data*

Tahapan split data merupakan proses krusial untuk mempersiapkan dataset dalam melatih dan mengevaluasi model segmentasi U-Net. Proses ini diawali dengan persiapan citra. Berbeda dengan data Landsat yang seringkali memerlukan penyeragaman ukuran, penelitian ini menggunakan tiga tile Sentinel-2 MGRS (48MWB, 48MUC, dan 48MVC). Tile ini secara inheren atau berhubungan erat sudah memiliki ukuran dan proyeksi yang seragam (10980 x 10980 piksel pada resolusi 10m), sehingga proses pemotongan (*clipping*) untuk standardisasi ukuran tidak diperlukan.

Sebelum data dibagi, citra *multiband* (5 kanal) dan citra *mask* (label) dipecah menjadi beberapa potongan (*patch*) yang lebih kecil agar dapat diproses secara efisien oleh model. Proses ini, atau *image patching*, membagi setiap tile besar menjadi *patch* berukuran 512×512 piksel. Untuk memastikan kontinuitas atau kesinambungan spasial dan memperbanyak jumlah data, proses ini dilakukan dengan tumpang tindih (*overlapping*) sebesar 20%.

Setelah proses *patching*, ditemukan bahwa tidak semua *patch* yang dihasilkan layak digunakan. Beberapa *patch* sebagian besar hanya berisi piksel hitam (nilai 0), yang merupakan area no-data (area di luar batas tile). *Patch* seperti ini tidak memuat informasi yang relevan dan dapat menurunkan kualitas dataset serta memengaruhi kinerja model jika tetap digunakan.

Untuk mengatasi hal tersebut, diterapkan proses *image filtering*. Suatu *patch* dinilai tidak layak dan akan dihapus apabila kandungan piksel hitam (nilai 0) di dalamnya melebihi *threshold* 50%. *Patch* yang memenuhi kriteria ini, beserta citra *mask* pasangannya, dihapus dan tidak disertakan dalam tahap selanjutnya. Nilai 50% digunakan sebagai *threshold* heuristik yang umum digunakan dalam praktik pengolahan citra dan *deep learning*, terutama untuk *quality control* pada *patch-based* dataset. Beberapa penelitian segmentasi berbasis *patch* tidak secara jelas menyebutkan angka *threshold* tertentu, namun melakukan penghapusan *patch* yang didominasi area no-data atau

background. Oleh karena itu, nilai 50% dipilih sebagai batas.

Berdasarkan proses *image patching* pada ketiga tile, diperoleh total 2,028 *patch* berpasangan (citra *multiband* dan *mask*). Setelah melalui proses *image filtering*, sebanyak 514 *patch* dinyatakan tidak layak dan berhasil dihapus. Dengan demikian, jumlah total citra layak yang digunakan dalam penelitian ini adalah 1,514 *patch* berpasangan.

Citra yang telah dinyatakan layak inilah yang kemudian digunakan untuk proses *split data* menjadi tiga bagian,training, *testing* dan *validation*. Dengan total pembagian dengan rasio 70% (training) sebanyak 1211, 15% (testing) sebanyak 152 dan 15% (validation) sebanyak 151. Pembagian data dilakukan secara acak pada level *patch* dengan tetap menjaga kesesuaian antara citra dan *mask*. Persebaran pixel *burned* dan *unburned* pada salah satu *patch* yaitu pada bagian *training* dapat terlihat pada Gambar 4.9. Ditunjukan distribusi frekuensi piksel pada citra berdasarkan grafik batang tersebut, terlihat bahwa frekuensi piksel yang diklasifikasian sebagai *burned* (1) sebanyak 31.032 piksel. Sementara itu, area yang diklasifikasikan sebagai *Unburned* (0) jauh lebih dominan mencangkup 231.112 pixel.

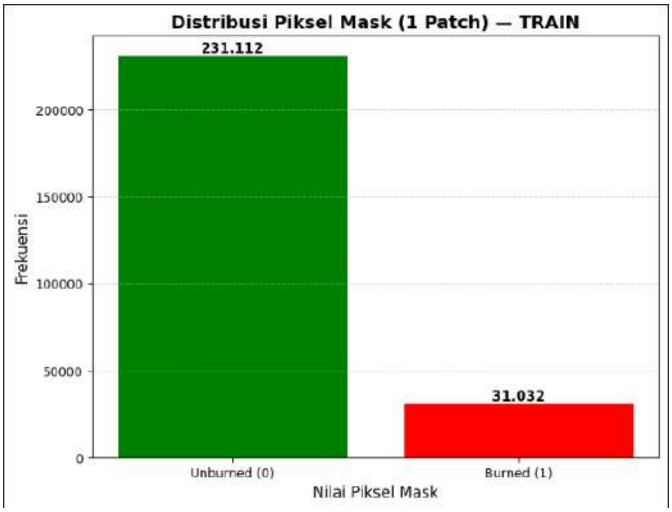

Gambar 4.9 Distribusi Piksel

4.7 Model U-Net

Pada tahap *training* model, data yang telah melalui proses *split data* (data latih dan data validasi) digunakan sebagai masukan dalam proses pelatihan model U-Net. Arsitektur U-Net yang digunakan merujuk pada rancangan sebagaimana ditampilkan pada pada Gambar 3.8, dengan struktur simetris *encoder-decoder* yang dirancang khusus untuk segmentasi citra. Model U-Net dikompilasi menggunakan *hyperparameter* yang telah ditentukan. Berupa fungsi *loss binary_crossentropy* dan *Optimizer* yang digunakan adalah Adam dengan *learning rate* awal sebesar 0.0001, bertujuan untuk mengoptimalkan konvergensi terhadap segmentasi biner. Selain *loss*, model juga melacak serangkaian metrik evaluasi segmentasi, yaitu *Intersection over Union* (IoU), *Dice Coefficient* dan akurasi.

Pada proses *training* dilengkapi dengan dua mekanisme *callback*, yaitu *EarlyStopping* dan *ReduceLROnPlateau*, *EarlyStopping* berfungsi menghentikan *training* ketika *loss* berhenti membaik dan mencegah *overfitting* dan *ReduceLROnPlateau* berfungsi menjaga proses *training* tetap efektif dan memaksimalkan kinerja model dan mencegah *overfitting*. Jadi kedua fungsi tersebut secara jelasnya masing-masing berfungsi menghentikan *training* ketika tidak terjadi perbaikan pada `val_loss` setelah lima *epoch* berturut-turut, serta menurunkan nilai *learning rate* sebesar 50% jika tidak terjadi penurunan `val_loss` dalam tiga *epoch*. Model dilatih dengan menggunakan jumlah *epoch* 100 dan ukuran *batch size* 4. Penentuan ini berdasarkan paper rujukan Prabowo [2] dengan melakukan modifikasi salah satunya seperti pengurangan *epoch* dari 200 menjadi 100 dikarenakan komputasi yang kurang memumpuni.

Pada Gambar 4.10 menunjukkan grafik riwayat proses pada *training* dan data *validation* untuk metrik *loss* serta *accuracy* dengan memanfaatkan *binary accuracy* dan *binary cross entropy* beserta sumbu X mempresentasikan *epoch* dan sumbu y untuk mempresentasikan nilai *accuracy* atau nilai *loss*. Berdasarkan grafik *loss*, terlihat bahwa nilai *training loss* mengalami penurunan sangat tajam pada beberapa epoch awal, kemudian berangsur stabil hingga

mencapai nilai yang rendah pada akhir pelatihan. Kurva *validation loss* menunjukkan pola yang hampir sama, dengan penurunan yang konsisten dan tanpa adanya fluktuasi ekstrem. Pola grafik antara kedua kurva ini mengindikasikan bahwa model mampu belajar secara efektif tanpa menunjukkan tanda-tanda *overfitting*, karena performa pada data validasi tetap sejalan dengan performa pada data *training*.

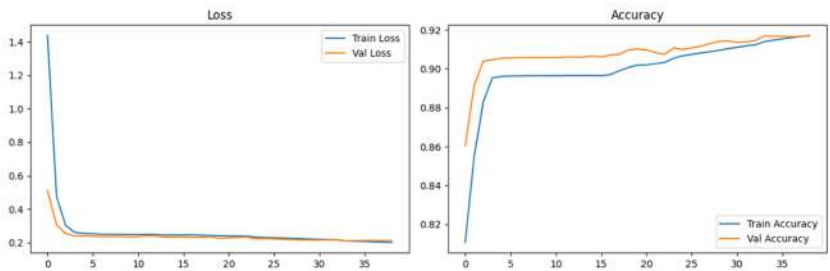

Gambar 4.10 Grafik *Loss* dan *Accuracy* Model

Grafik *accuracy* juga memperlihatkan tren peningkatan yang stabil baik pada *training accuracy* maupun *validation accuracy*. Pada awal pelatihan, akurasi validasi bahkan sedikit lebih tinggi dibandingkan akurasi *training*, yang menandakan bahwa data validasi tidak lebih sulit dipelajari oleh model. Seiring bertambahnya epoch, kedua kurva akurasi bergerak semakin mendekati satu sama lain dan mencapai nilai yang tinggi pada akhir pelatihan, menunjukkan kemampuan model dalam melakukan generalisasi dengan baik. Generalisasi yang baik yaitu kemampuan model untuk memberikan hasil yang akurat pada data yang belum pernah dilatih, yang ditunjukkan oleh nilai akurasi *training* dan *validation* yang sama-sama tinggi dan saling mendekati. Secara keseluruhan, pola yang stabil pada kurva *loss* dan *accuracy* menunjukkan bahwa proses pelatihan berjalan optimal.Secara keseluruhan, pola yang stabil pada kurva *loss* dan *accuracy* menunjukkan bahwa proses pelatihan berjalan optimal.

Pada Tabel 4.3 Model U-Net yang digunakan dalam penelitian ini terdiri atas 18 lapisan utama dengan struktur *encoder-decoder* yang simetris yang memiliki proses *donwsampling* dan *upsampling* di dalamnya. *Downsampling* merupakan proses pengurangan resolusi

spasial citra yang bertujuan untuk mengekstraksi fitur-fitur penting dan konteks global citra. Sebaliknya, *upsampling* adalah proses peningkatan kembali resolusi spasial citra untuk menghasilkan output dengan ukuran yang sama seperti citra masukan, sehingga memungkinkan prediksi pada tingkat piksel. Arsitektur ini diawali oleh input layer berukuran 512x512 piksel dengan beberapa kanal band citra sebagai masukan. Pada bagian *encoder*, terdapat empat tahap konvolusi dan *max pooling* yang berfungsi untuk mengekstraksi fitur spasial dari citra dengan resolusi yang semakin kecil namun memiliki jumlah filter yang meningkat. Lapisan konvolusi pertama menghasilkan keluaran berukuran 512x512x64, kemudian dilakukan proses *downsampling* hingga berturut-turut menjadi 256x256x128, 128x128x256, dan 64x64x512. Tahap paling bawah atau *bottleneck* memiliki ukuran keluaran 32x32x1024, yang merepresentasikan fitur paling kompleks dari citra masukan.

Selanjutnya pada bagian *decoder*, dilakukan proses *upsampling* menggunakan lapisan *Conv2DTranspose* untuk mengembalikan resolusi spasial citra ke ukuran semula. Setiap tahap *upsampling* diikuti oleh proses *concatenate* (penggabungan data menjadi satu kesatuan) yang menggabungkan hasil *upsampling* dengan keluaran dari lapisan *encoder* yang memiliki ukuran spasial sama (*skip connection*), sehingga informasi detail pada citra dapat dipertahankan. Proses ini berlangsung secara bertahap dengan ukuran keluaran 64x64x512, 128x128x256, 256x256x128, hingga akhirnya kembali menjadi 512x512x64.

Lapisan terakhir berupa *Conv2D* dengan fungsi aktivasi sigmoid menghasilkan keluaran berukuran 512x512x1 yang merepresentasikan peta segmentasi biner, yaitu antara area *burned* dan *unburned*. Secara keseluruhan, struktur U-Net ini memiliki kemampuan untuk mengekstraksi fitur global maupun detail lokal dari citra Sentinel-2, sehingga sangat sesuai digunakan untuk tugas segmentasi spasial seperti klasifikasi area kebakaran hutan.

Tabel 4.3 Struktur Layer dan Output Shape Model U-Net

Layer (type)	**Output Shape**
input_layer (InputLayer)	(None, 512, 512, 5)
conv2d (Conv2D)	(None, 512, 512, 64)
conv2d_1 (Conv2D)	(None, 512, 512, 64)
max_pooling2d (MaxPooling2D)	(None, 256, 256, 64)
conv2d_2 (Conv2D)	(None, 256, 256, 128)
conv2d_3 (Conv2D)	(None, 256, 256, 128)
max_pooling2d_1 (MaxPooling2D)	(None, 128, 128, 128)
conv2d_4 (Conv2D)	(None, 128, 128, 256)
conv2d_5 (Conv2D)	(None, 128, 128, 256)
max_pooling2d_2 (MaxPooling2D)	(None, 64, 64, 256)
conv2d_6 (Conv2D)	(None, 64, 64, 512)
conv2d_7 (Conv2D)	(None, 64, 64, 512)
max_pooling2d_3 (MaxPooling2D)	(None, 32, 32, 512)
conv2d_8 (Conv2D)	(None, 32, 32, 1024)
conv2d_9 (Conv2D)	(None, 32, 32, 1024)
conv2d_transpose (Conv2DTranspose)	(None, 64, 64, 512)
concatenate (Concatenate)	(None, 64, 64, 1024)
conv2d_10 (Conv2D)	(None, 64, 64, 512)
conv2d_11 (Conv2D)	(None, 64, 64, 512)
conv2d_transpose_1 (Conv2DTranspose)	(None, 128, 128, 256)
concatenate_1 (Concatenate)	(None, 128, 128, 512)
conv2d_12 (Conv2D)	(None, 128, 128, 256)
conv2d_13 (Conv2D)	(None, 128, 128, 256)
conv2d_transpose_2 (Conv2DTranspose)	(None, 256, 256, 128)
concatenate_2 (Concatenate)	(None, 256, 256, 256)
conv2d_14 (Conv2D)	(None, 256, 256, 128)
conv2d_15 (Conv2D)	(None, 256, 256, 128)
conv2d_transpose_3 (Conv2DTranspose)	(None, 512, 512, 64)
concatenate_3 (Concatenate)	(None, 512, 512, 128)
conv2d_16 (Conv2D)	(None, 512, 512, 64)
conv2d_17 (Conv2D)	(None, 512, 512, 64)
conv2d_18 (Conv2D)	(None, 512, 512, 1)

Perubahan Output Shape pada Tabel 4.2 mengikuti prinsip dasar arsitektur U-Net. Pada lapisan Conv2D digunakan kernel berukuran 3×3 dengan stride 1 dan *padding same*, sehingga ukuran spasial citra tetap, sedangkan jumlah channel meningkat sesuai jumlah filter. Lapisan MaxPooling2D dengan ukuran pool 2×2 menyebabkan penurunan resolusi spasial menjadi setengah dari ukuran sebelumnya. Sebaliknya, lapisan Conv2DTranspose digunakan untuk meningkatkan kembali resolusi spasial citra pada bagian *decoder*. Proses concatenate menggabungkan fitur dari *encoder* dan *decoder* dengan ukuran spasial yang sama, sehingga jumlah channel bertambah. Pada lapisan terakhir digunakan Conv2D dengan kernel 1×1 untuk menghasilkan output segmentasi berukuran 512×512 dengan satu channel sebagai hasil prediksi akhir.

4.8 Evaluasi Model

Evaluasi model U-Net dilakukan untuk mengukur performa model secara kuantitatif pada data uji (*test set*), yang merupakan 15% data yang belum pernah dilihat oleh model selama proses *training* maupun validasi. Evaluasi ini menggunakan lima metrik utama yang telah didefinisikan saat kompilasi model, yaitu Akurasi, *Intersection over Union* (IoU), *Dice Coefficient* dan *Binary Crossentropy*.

Model mencapai nilai Akurasi sebesar 0.88386, yang menunjukkan bahwa mayoritas piksel pada citra berhasil diklasifikasikan dengan benar (*burned* vs. *unburned*). Nilai *Intersection over Union* (IoU) diperoleh sebesar 0.40269, menunjukkan bahwa model memiliki tingkat kesesuaian antara hasil prediksi dan data referensi sebesar sekitar 40,26%, menunjukkan bahwa tingkat tumpang tindih antara area *Burned Area* hasil prediksi model dan area referensi masih berada pada tingkat sedang. Mengindikasikan bahwa model telah mampu mendeteksi keberadaan area terbakar, namun masih terdapat ketidaktepatan dalam menentukan batas dan luasan area tersebut. Nilai ini dapat dikategorikan sebagai tingkat akurasi sedang, yang mengindikasikan bahwa model sudah mampu mengenali pola area dengan cukup baik, namun masih memerlukan peningkatan lebih

lanjut agar hasil segmentasi menjadi lebih akurat dan konsisten. Selain itu, *Dice Coefficient* yang diperoleh mencapai 0.57417, menunjukkan bahwa model memiliki tingkat kesamaan antara hasil prediksi dan data referensi sebesar 57,41%. Model telah mampu mengidentifikasi area target dengan cukup baik, namun masih terdapat perbedaan yang cukup signifikan antara hasil segmentasi dan kondisi sebenarnya sehingga diperlukan peningkatan lebih lanjut pada tahap pelatihan atau prapemrosesan data. Sementara itu, nilai *Binary Crossentropy* adalah 0.20875, menunjukkan bahwa tingkat kesalahan prediksi model relatif rendah, yang mengindikasikan bahwa model telah mampu mempelajari perbedaan antara kelas dengan cukup baik. Meskipun hasil ini menunjukkan performa yang cukup baik, masih terdapat ruang untuk peningkatan lebih lanjut agar model dapat menghasilkan prediksi yang lebih akurat dan stabil pada berbagai kondisi data. Hasil evaluasi model ditunjukkan pada Tabel 4.4.

Tabel 4.4 Hasil Evaluasi Model

Evaluasi Model	**Nilai**
Binary Accuracy	0.88386
IoU	0.40269
Dice Coefficient	0.57417
BCE	0.20875

Berdasarkan Tabel 4.4, model menunjukkan nilai *Binary Accuracy* yang tinggi, namun nilai *IoU* dan *Dice Coefficient* masih berada pada tingkat sedang. Hal ini mengindikasikan bahwa meskipun sebagian besar piksel berhasil diklasifikasikan dengan benar, kemampuan model dalam memprediksi area objek secara presisi masih dapat ditingkatkan. Nilai *BCE* yang relatif rendah menunjukkan bahwa proses pelatihan telah berjalan dengan baik dan model mampu meminimalkan kesalahan prediksi.

Tabel 4.5 menunjukkan *confusion matrix* hasil evaluasi model pada data uji dalam satuan piksel. Berdasarkan tabel tersebut, model menghasilkan jumlah prediksi yang cukup baik dalam membedakan

area terbakar dan tidak terbakar. Pada kelas *Yes* (area terbakar), model berhasil mengklasifikasikan 34.658.959 piksel sebagai benar terbakar (TP), sementara hanya 819.057 piksel yang salah diklasifikasikan sebagai tidak terbakar (FN). Nilai *true positive* yang sangat tinggi dibandingkan *false negative* menunjukkan bahwa model memiliki kemampuan deteksi area terbakar yang kuat, serta risiko terlewatnya area terbakar relatif kecil. Pada kelas *No* (area tidak terbakar), model memprediksi 1.849.258 piksel dengan benar sebagai tidak terbakar (TN), namun masih terdapat 2.518.614 piksel yang salah diklasifikasikan sebagai terbakar (FP). Nilai *false positive* yang relatif lebih tinggi dibanding *true negative* mengindikasikan bahwa model cenderung lebih sensitif (lebih banyak mendeteksi piksel sebagai terbakar), sehingga beberapa area yang sebenarnya tidak terbakar ikut terklasifikasi sebagai terbakar. Kondisi ini lazim terjadi pada model deteksi kebakaran karena umumnya lebih diprioritaskan untuk menghindari kesalahan mendeteksi area terbakar sebagai aman (meminimalkan FN).

Secara keseluruhan, proporsi TP yang sangat besar menunjukkan bahwa model memiliki performa yang baik dalam mengidentifikasi area terbakar. Meskipun masih terdapat kesalahan pada kategori FP, pola ini masih dapat diterima untuk aplikasi deteksi kebakaran, di mana kesalahan tipe FN (kebakaran yang terlewat) jauh lebih berisiko dibanding FP.

Tabel 4.5 *Confussion Matrix* Hasil Prediksi Model

		Predicted	
		Burned	***Unburned***
Actual	***Burned***	34,658,959 (TP)	819,057 (FN)
	Unburned	2,518,614 (FP)	1,849,258 (TN)

Selain evaluasi kuantitatif, dilakukan pula analisis kualitatif melalui visualisasi beberapa hasil prediksi model pada *patch* data uji, seperti yang ditunjukkan pada Gambar 4.11. Visualisasi ini menyajikan

perbandingan antara tiga gambar yaitu citra *multiband* masukan (yang divisualisasikan sebagai *false color* dari B11, B8, B4), citra *ground truth* (masker/label sebenarnya), dan citra prediksi (masker hasil segmentasi model U-Net). Patch pertama mendapat kan *accuracy* sekitar 0,77, *IoU* sebesar 0,32 dan *Dice Coefficient* sebesar 0,68. Lalu *patch* kedua *accuracy* sekitar 0,74, *IoU* sebesar 0,41 dan *Dice Coefficient* sebesar 0,58.

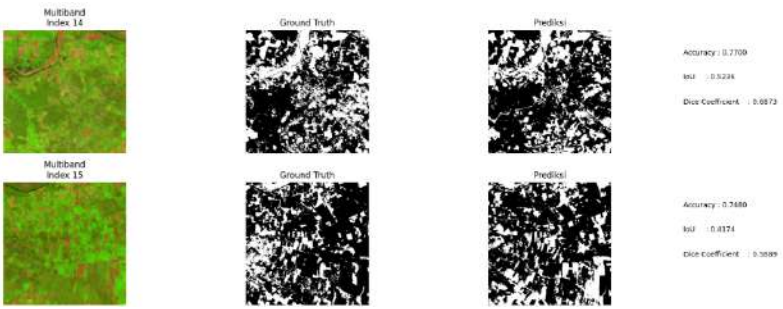

Gambar 4.11 Citra Prediksi Segmentasi model U-Net

4.9 Pembahasan

Penelitian ini mengimplementasikan arsitektur model U-Net untuk segmentasi *burned area* dari citra Sentinel-2. Berbeda dari pendekatan standar yang mungkin hanya menggunakan kanal RGB atau *false color* dasar, penelitian ini menggunakan lima kanal (5 band) input yang komprehensif (secara menyeluruh). Input ini terdiri atas tiga kanal spektral utama (Band 4-Red, Band 8-NIR, Band 11-SWIR) dan dua kanal indeks turunan, yaitu *Normalized Difference Vegetation Index* (NDVI) dan *Normalized Burn Ratio* (NBR). Strategi ekstraksi fitur ini dirancang untuk memperkaya informasi yang diberikan kepada model. Integrasi NDVI dan NBR bertujuan agar model tidak hanya belajar dari nilai reflektansi mentah, tetapi juga dari informasi yang secara eksplisit menyoroti kondisi kesehatan vegetasi (NDVI) dan kelembaban biomassa serta area terbakar (NBR), yang sangat relevan untuk tugas segmentasi ini.

Implementasi model U-Net (dijelaskan pada Gambar 3.8) dilatih menggunakan data *patch* berukuran 512x512 piksel. proses *training*

dikonfigurasi secara spesifik untuk mengoptimalkan segmentasi. Penggunaan dipilih sebagai fungsi kerugian utama karena secara langsung mengoptimalkan metrik *Intersection over Union* (IoU), yang merupakan standar evaluasi utama dalam segmentasi. Kurva *loss* dan IoU untuk data *training* dan validasi bergerak secara konsisten (turun untuk *loss*, naik untuk IoU) tanpa adanya fluktuasi tajam atau divergensi (penyebaran). Hal ini mengindikasikan bahwa model mampu melakukan generalisasi dengan baik dan tidak mengalami *overfitting*, didukung oleh mekanisme *callback EarlyStopping* dan *ReduceLROnPlateu*.

Untuk menjawab rumusan masalah terkait evaluasi performa model, dilakukan pengujian kuantitatif pada test set. Hasil evaluasi menunjukkan gambaran performa yang menarik. Model mencapai nilai Akurasi yang relatif tinggi, yaitu 0.88386 (88.38%), namun menunjukkan performa yang lebih moderat (berada di pertengahan, tidak baik dan tidak buruk) pada metrik segmentasi spesifik, dengan *Intersection over Union* (IoU) sebesar 0.40269 (40.26%) dan *Dice Coefficient* sebesar 0.57417 (57.41%).

Analisis dari diskrepansi ini antara Akurasi yang tinggi dan IoU/Dice yang moderat merupakan temuan kunci dalam pembahasan ini. Akurasi yang tinggi kemungkinan besar disebabkan oleh kondisi *class imbalance* (ketidakseimbangan kelas) yang ekstrem dalam dataset. Sebagian besar area dalam tile citra adalah *Unburned* (0), yang direpresentasikan sebagai piksel hitam pada *mask ground truth*. Seperti yang teridentifikasi selama analisis data, banyak *patch* hasil splitting yang hampir seluruhnya atau bahkan sepenuhnya hitam (tidak ada area terbakar). Model menjadi sangat baik dalam memprediksi kelas dominan ini (area *Unburned*). Akurasi yang tinggi (88.38%) tercapai karena model dengan benar memprediksi mayoritas piksel *Unburned*, namun metrik ini gagal mencerminkan performa model dalam mengenali kelas minoritas yang justru menjadi target utama, yaitu *Burned* (1).

Oleh karena itu, nilai IoU (40.26%) dan Dice (57.41%) adalah

indikator performa yang lebih jujur dan relevan untuk penelitian ini. Nilai-nilai ini, yang berada di kategori sedang, menunjukkan bahwa model sudah mampu mengenali pola umum area terbakar, namun masih memiliki keterbatasan signifikan dalam hal presisi batas segmentasi. Hal ini diperkuat oleh nilai *Binary Crossentropy* sebesar 0.20875, yang tergolong rendah, menandakan bahwa secara umum model cukup percaya diri dalam prediksinya, meskipun prediksi tersebut tidak selalu presisi secara spasial (seperti yang ditunjukkan oleh IoU).

Keterbatasan ini juga terlihat secara kualitatif, Pada beberapa *patch*, model kesulitan mengidentifikasi area terbakar yang kecil atau yang memiliki pola spektral ambigu. Selain itu, masalah *class imbalance* ini juga berdampak pada *ground truth* itu sendiri. Jika *patch ground truth* sepenuhnya hitam (tidak ada area terbakar), dan model juga memprediksi sepenuhnya hitam, maka semua metrik untuk *patch* tersebut (Akurasi, IoU, Dice) akan tinggi, meskipun model tersebut mungkin tidak memiliki kemampuan sama sekali untuk mendeteksi area terbakar jika ada. Implementasi arsitektur U-Net dengan 5 kanal input telah dilakukan, namun performanya dibatasi oleh karakteristik dataset. Kinerja moderat pada IoU/Dice bukanlah kegagalan model untuk belajar, melainkan refleksi dari tantangan segmentasi pada dataset dengan *class imbalance*. penanganan *class imbalance* belum diterapkan secara jelas dan sengaja dibiarkan apa adanya untuk mengevaluasi kemampuan dasar arsitektur U-Net dalam kondisi dataset nyata yang memang sangat tidak seimbang. Pada kasus kebakaran hutan, secara spasial area terbakar selalu jauh lebih kecil dibandingkan area tidak terbakar, sehingga ketidakseimbangan kelas merupakan karakteristik alami data. Dampak dari ketidakseimbangan tersebut kemudian dianalisis melalui perbandingan metrik evaluasi, khususnya antara akurasi dan IoU/Dice, dan menjadi dasar rekomendasi pada penelitian selanjutnya.

Tabel 4.6 Perbandingan performa segmentasi model U-Net

Evaluasi Model	Penelitian Penulis	Penelitian Made, dkk. (2023)	Penelitian Alber (2025)
Binary Accuracy	0.88	0.95	0.94
IoU	0.40	0.57	0.78
Dice Coefficient	0.57	0.69	0.83
BCE	0.21	0.21	0.14

Berdasarkan Tabel 4.6, performa model U-Net yang dikembangkan dalam penelitian ini menunjukkan karakteristik yang berbeda dibandingkan dengan dua penelitian rujukan. Nilai *Binary Accuracy* model berada pada kisaran tinggi (0.88), namun tetap lebih rendah dibandingkan penelitian Made dkk. (2023) maupun Alber Analafean, yang masing-masing mencapai 0.95 dan 0.94. Perbedaan ini konsisten dengan temuan analisis bahwa akurasi bukan indikator yang sensitif terhadap ketidakseimbangan kelas. Pada metrik yang lebih relevan untuk segmentasi, yaitu IoU dan *Dice Coefficient*, model pada penelitian ini menunjukkan performa yang berada pada kategori moderat (0.40 dan 0.40). Nilai ini secara jelas lebih rendah dibandingkan dua penelitian pembanding, di mana penelitian Made dkk. mendapatkan IoU 0.57 dan Dice 0.69, sedangkan penelitian Alber Analafean bahkan mencapai tingkat yang jauh lebih tinggi (IoU 0.78 dan Dice 0.83). Kesenjangan metrik ini menunjukkan bahwa meskipun model mampu mengenali pola umum area terbakar, presisi segmentasi spasialnya masih terbatas jika dibandingkan dengan studi sebelumnya yang tampaknya memiliki kondisi data yang lebih seimbang atau fitur yang lebih mudah dipisahkan secara spektral. Dari sisi *Binary Crossentropy*, nilai BCE penelitian ini (0.20) sejalan dengan nilai dari penelitian Made dkk. (0.21) meskipun masih lebih tinggi dari Alber Analafean (0.14), mengindikasikan bahwa tingkat kepercayaan model terhadap prediksi cukup baik, tetapi tidak sematang model yang dilatih pada dataset dengan distribusi kelas yang lebih bersahabat.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

1. Pendekatan segmentasi citra berbasis model U-Net telah berhasil diterapkan untuk segmentasi burned area menggunakan citra satelit Sentinel-2 di wilayah penelitian (Tile 48MWB, 48MUC, dan 48MVC). Proses data *preprocessing* yang melibatkan *cloud masking* berbasis SCL (*Scene Classification Layer*), *image patching* (512x512 piksel), dan *filtering* (untuk menghilangkan *patch* dengan dominan no-data) dalam mempersiapkan data masukan yang bersih untuk model. Salah satu kontribusi penting dalam penelitian ini adalah penggunaan lima kanal (5 band) input, yang terdiri atas tiga kanal spektral (Band 4-Red, Band 8-NIR, Band 11-SWIR) serta dua kanal indeks turunan (NDVI dan NBR). Integrasi kelima kanal ini dirancang untuk memperkaya informasi yang diterima model, di mana NDVI membantu membedakan vegetasi sehat dan NBR sensitif terhadap kelembaban biomassa dan area terbakar, sehingga model memperoleh informasi yang lebih komprehensif.
2. Model U-Net yang dilatih menggunakan optimizer Adam menunjukkan performa pelatihan yang stabil, tanpa indikasi *overfitting*, yang divalidasi oleh kurva *training* dan *validation* yang konsisten. Namun, hasil evaluasi model pada *test set* menunjukkan gambaran performa yang harus ditafsirkan dengan hati-hati. Model berhasil mencapai Akurasi yang tinggi sebesar 0.88386, namun menunjukkan performa moderat pada metrik segmentasi spesifik, dengan *Intersection over Union* (IoU) sebesar 0.40269 dan *Dice Coefficient* sebesar 0.57417. Diskrepansi antara akurasi yang tinggi dan IoU/Dice yang moderat ini mengindikasikan bahwa performa model sangat dipengaruhi oleh ketidakseimbangan kelas (*class imbalance*) yang ekstrem dalam dataset. Akurasi tinggi tercapai karena model sangat baik dalam memprediksi kelas dominan (piksel

Unburned), sementara IoU dan Dice yang lebih relevan untuk tugas segmentasi menunjukkan bahwa model sudah memiliki kemampuan dasar untuk mengenali pola area terbakar, namun masih memiliki keterbatasan signifikan dalam hal presisi batas segmentasi.

5.2 Saran

Berdasarkan temuan dan keterbatasan dalam penelitian ini, berikut adalah beberapa saran yang dapat dipertimbangkan untuk pengembangan penelitian selanjutnya:

1. Penanganan *Class Imbalance*. Masalah utama dalam penelitian ini adalah dataset yang sangat tidak seimbang. Untuk penelitian selanjutnya, disarankan untuk menerapkan strategi penanganan data yang lebih canggih, seperti menyaring *patch* pelatihan secara lebih ketat (hanya menggunakan *patch* yang mengandung persentase minimum area terbakar) atau menerapkan teknik augmentasi dan *oversampling* pada *patch* yang mengandung kelas minoritas (*Burned*). Eksplorasi fungsi *Loss*. Mengingat data yang tidak seimbang, Disarankan untuk mengeksplorasi penggunaan fungsi *loss* yang dirancang khusus untuk menangani *class imbalance* dalam segmentasi, seperti *Focal Loss* atau *Tversky Loss*, yang dapat memaksa model untuk lebih fokus mempelajari kelas minoritas yang sulit diprediksi dan berpotensi meningkatkan *IoU* dan D*ice*, untuk implementasi dan evaluasinya berada di luar ruang lingkup penelitian.
2. Pengembangan Arsitektur Model. Meskipun U-Net standar telah digunakan, penelitian selanjutnya dapat mengeksplorasi arsitektur yang lebih canggih, seperti *Attention* U-Net atau U-Net++. Mekanisme *attention* mungkin dapat membantu model untuk lebih fokus pada batas-batas area terbakar yang kompleks dan meningkatkan presisi spasial (IoU). Perluasan skala dan validasi lapangan. Penelitian ini terbatas pada tiga tile Sentinel-2. Disarankan untuk memperluas cakupan spasial ke seluruh wilayah Sumatera Selatan atau provinsi lain, serta

menggunakan rentang waktu yang lebih panjang untuk analisis temporal. Selain itu, validasi hasil segmentasi dengan data *ground truth* lapangan (jika tersedia) akan sangat meningkatkan nilai dan keandalan model. Optimasi komputasi. *Training* model *deep learning* pada data citra satelit memerlukan sumber daya komputasi (GPU) yang besar. Disarankan untuk memanfaatkan platform komputasi awan (*cloud computing*) seperti Google Colab Pro, Google Cloud Platform (GCP), atau layanan serupa untuk memungkinkan pelatihan pada dataset yang lebih besar dan eksperimentasi *hyperparameter* yang lebih ekstensif.

DAFTAR PUSTAKA

[1] K. L. H. dan Kehutanan (KLHK), *Delapan titik karhutla di sumsel telah berhasil dipadamkan*, 2023. sumber: https://ppid.menlhk.go.id/berita/siaran-pers/7416/delapan-titik-karhutla-di-sumsel-telah-berhasil-dipadamkan

[2] Y. Prabowo dkk., "Deep learning dataset for estimating burned areas: Case study, indonesia", *Data*, vol. 7, 6 Juni 2022.

[3] A. Taylor, I. Dronova, A. Sigona, dan M. Kelly, "Using sentinel-2 imagery to measure spatiotemporal changes and recovery across three adjacent grasslands with different fire histories", *Remote Sensing*, vol. 16, 12 Juni 2024.

[4] I. L. Sari, C. J. Weston, G. J. Newnham, dan L. Volkova, "Assessing accuracy of land cover change maps derived from automated digital processing and visual interpretation in tropical forests in indonesia", *Remote Sensing*, vol. 13, no. 8, Apr. 2021.

[5] L. Ma, Y. Liu, X. Zhang, Y. Ye, G. Yin, dan B. A. Johnson, *Deep learning in remote sensing applications: A meta-analysis and review*, Juni 2019.

[6] O. Ronneberger, P. Fischer, dan T. Brox, "U-net: Convolutional networks for biomedical image segmentation", *ArXiv*, vol. abs/1505.04597, 2015. sumber: https://api.semanticscholar.org/CorpusID:3719281

[7] L. Knopp, M. Wieland, M. Rättich, dan S. Martinis, "A deep learning approach for burned area segmentation with Sentinel-2 data", *Remote Sensing*, vol. 12, no. 15, 2020.

[8] B. Kim, K. Lee, dan S. Park, "Burned-area mapping using post-fire planetscope images and a convolutional neural network", *Remote Sensing*, vol. 16, 14 Juli 2024.

[9] F. Carriello[1], L. O. Anderson[2], dan M. Adami[1], "Multitemporal analysis of the spectral response of scars of burnt areas using the landsat/etm sensor", tech. rep., 2007. sumber: http://www.cptec.inpe.br/queimadas/

[10] D. P. Roy, Y. Jin, P. E. Lewis, dan C. O. Justice, “Prototyping a global algorithm for systematic fire-affected area mapping using modis time series data”, *Remote Sensing of Environment*, vol. 97, hlmn. 137–162, 2 Juli 2005.

[11] M. A. Belenguer-Plomer, M. A. Tanase, E. Chuvieco, dan F. Bovolo, “CNN-based burned area mapping using radar and optical data”, *Remote Sensing of Environment*, vol. 260, hlmn. 112 468, 2021. sumber: https://doi.org/10.1016/j.rse.2021.112468

[12] M. Gargiulo, D. A. G. Dell’aglio, A. Iodice, D. Riccio, dan G. Ruello, *A cnn-based super-resolution technique for active fire detection on sentinel-2 data*, 2019.

[13] O. Hagolle dkk., “Sentinel-2 surface reflectance products generated by cnes and dlr: Methods, validation and applications”, di dalam *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. 5, Copernicus GmbH, Juni 2021, hlmn. 9–15.

[14] A. Zaitunah, S. Samsuri, A. G. Ahmad, dan R. A. Safitri, “Normalized difference vegetation index (ndvi) analysis for land cover types using landsat 8 oli in besitang watershed, indonesia”, di dalam *IOP Conference Series: Earth and Environmental Science*, vol. 126, Institute of Physics Publishing, Mar. 2018.

[15] E. Alcaras, D. Costantino, F. Guastaferro, C. Parente, dan M. Pepe, “Normalized burn ratio plus (nbr+): A new index for sentinel-2 imagery”, *Remote Sensing*, vol. 14, 7 Apr. 2022.

[16] S. Zahabnazouri, P. Belmont, S. David, P. E. Wigand, M. Elia, dan D. Capolongo, “Detecting burn severity and vegetation recovery after fire using dnbr and dndvi indices: Insight from the bosco difesa grande, gravina in southern italy”, *Sensors*, vol. 25, 10 Mei 2025.

[17] M. Manley, *Near-infrared spectroscopy and hyperspectral imaging: Non-destructive analysis of biological materials*, Des. 2014.

[18] N. Zrira, A. Jimi, M. Di Nardo, I. Elafi, M. Gallab, dan R. Chahdi El Ouazzani, “GCBAM-UNet: Sun Glare Segmentation

Using Convolutional Block Attention Module", *Applied System Innovation*, vol. 7, no. 6, hlmn. 1–17, 2024.

[19] I. Made Murwantara, M. A. Witarsah, dan R. Hudi, "U-Net Wildfire Classification in Sumatra Island Based on Sentinel-2 and Landsat-8 Satellite Images", *Proceedings - International Conference on Smart-Green Technology in Electrical and Information Systems, ICSGTEIS*, no. November, hlmn. 59–64, 2023.

[20] W. K. Baek, M. J. Lee, dan H. S. Jung, "Land cover classification from rgb and nir satellite images using modified u-net model", *IEEE Access*, vol. 12, hlmn. 69 445–69 455, 2024.

[21] Y. Fan, Y. Zhang, B. Guo, X. Luo, Q. Peng, dan Z. Jin, "A hybrid sparrow search algorithm of the hyperparameter optimization in deep learning", *Mathematics*, vol. 10, 16 Agt. 2022.

[22] N. S. Keskar, D. Mudigere, J. Nocedal, M. Smelyanskiy, dan P. T. P. Tang, "On large-batch training for deep learning: Generalization gap and sharp minima", Feb. 2017. sumber: http://arxiv.org/abs/1609.04836

[23] D. P. Kingma dan J. Ba, "Adam: A method for stochastic optimization", Jan. 2017. sumber: http://arxiv.org/abs/1412.6980

[24] X. Glorot, A. Bordes, dan Y. Bengio, "Deep sparse rectifier neural networks", tech. rep., 2011.

[25] O. A. Somefun, K. F. Akingbade, dan F. M. Dahunsi, "The nlogistic-sigmoid function", *ArXiv*, vol. abs/2008.04210, 2020. sumber: https://api.semanticscholar.org/CorpusID:221090233

[26] Y. Lecun, E. Bottou, Y. Bengio, dan P. Haffner, "Gradient-based learning applied to document recognition", tech. rep., 1998.

[27] D. Scherer, A. Müller, dan S. Behnke, "Evaluation of pooling operations in convolutional architectures for object recognition", tech. rep., Okt. 2010. sumber: http://www.ais.uni-bonn.de

[28] V. Dumoulin dan F. Visin, "A guide to convolution arithmetic for deep learning", Jan. 2018. sumber: http://arxiv.org/abs/1603.07285

[29] G. Cheng, X. Xie, J. Han, L. Guo, dan G. S. Xia, "Remote sensing image scene classification meets deep learning:

Challenges, methods, benchmarks, and opportunities", *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 13, hlmn. 3735–3756, 2020.

[30] A. Balasch, M. Beinhofer, dan G. Zauner, *The Relative Confusion Matrix, a Tool to Assess Classifiablility in Large Scale Picking Applications*. 2020.

[31] R. Niri dkk., "Wound segmentation with u-net using a dual attention mechanism and transfer learning", *Journal of Imaging Informatics in Medicine*, 2025.

[32] X. Cao, Y. Tian, Z. Yao, Y. Zhao, dan T. Zhang, "Semantic segmentation network for unstructured rural roads based on improved sppm and fused multiscale features", *Applied Sciences (Switzerland)*, vol. 14, 19 Okt. 2024.

LAMPIRAN